Chapter 9

具身操作的泛化技术：从空间归纳偏置到多模态表征

本章导读

在经典计算机视觉中，泛化通常体现为模型对未见类别、光照或视角的判别能力；在具身操作中，识别只是决策的起点。模型即使准确识别出积木与凹槽，也可能在接近、接触和装配时失败。物理交互既要求“知其为何物”，也要求“明其何以触”。具身泛化的关键问题在于：受限的感知通道与动作空间，如何在变化的环境中维持几何关系与接触规律的自洽？

本章围绕“策略依靠何种结构在未见环境中维持有效行动”展开。首先建立部分可观测控制与分布偏移的数学描述，随后以 Transporter Networks 为解剖样本，剖析空间等变性、密集动作评分与条件互相关如何复用有限示范中的几何规律。在此基础上，进一步讨论开放语义与精细接触之间的矛盾，追踪从几何先验到多模态通用策略、从 ReconVLA 的局部重建到世界模型的动作后果预测的技术演进。

本节要点

泛化同时取决于**数据覆盖**、**表征塑形**、**动作表征与动力学一致性**。语义知识需要落实到可接触的几何位置，动作分布需要保留分离的可行解，未来预测需要服务于候选选择与反馈纠错。

9.1 问题形式化与泛化维度

9.1.1 从部分可观测状态到操作策略

夹爪的遮挡会隐藏接触点，深度图难以直接给出摩擦，单帧图像也未必能区分“物体已夹稳”与“夹爪刚刚闭合”。决策因此需要从有限观测中推断交互状态，这一过程

表 9.1: 本章主要符号及其物理含义。

符号	含义
s_t, o_t, l, h_t	真实状态、观测、语言指令、含历史的决策表征。
q_t	机器人关节、末端与夹爪等本体状态。
$\mathbf{u} = (r, c)$	俯视网格像素，行 r 对应世界 Y，列 c 对应世界 X。
$\mathbf{u}_p, \mathbf{u}_d, \vartheta_k$	抓取像素、放置像素、离散方向；引用图中的 p 表示抓点。
T_{AB}	将 B 坐标系中的坐标变换至 A 坐标系的齐次变换。
s_g, H, W, K, C, C_I, D	网格间距、网格高宽、方向数、查询边长、输入通道数、特征通道数。
$Q_{p,k}, F, S, V$	查询特征、全图键特征、未归一化评分、归一化动作分布。
A_t, τ	有限时域动作序列、扩散步；环境时间统一写 t。

可描述为部分可观测马尔可夫决策过程

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{O}, P, \Omega, r, \gamma, \rho_0), \qquad s_t = (s_t^{\text{obj}}, s_t^{\text{robot}}, s_t^{\text{scene}}). \tag{9.1.1}$$

其中 $P(s_{t+1} \mid s_t, a_t)$ 描述状态转移，$\Omega(o_t \mid s_t)$ 描述观测生成，ρ_0 是初始状态分布，r 是任务奖励。物体状态包括位姿与接触属性，机器人状态包括关节、末端与夹爪状态，场景状态包括容器、障碍和工作空间。实际观测可以写为

$$o_t = (I_t^{1:V}, q_t, \xi_t), \qquad h_t = f_\theta(o_{1:t}, a_{1:t-1}, l), \qquad a_t \sim \pi_\theta(\cdot \mid h_t, l), \tag{9.1.2}$$

其中 ξ_t 可包含深度、力觉或触觉，h_t 通过学习压缩观测与动作历史。例如，夹爪闭合后的两张图像可能十分相似，但一次抓取已稳定接触，另一次物体正在滑落；此前的夹爪运动和触觉变化帮助策略区分这两种状态，分别选择抬升与重新抓取。

图 9.1 展示视觉、语言与本体状态的融合过程。语言指定任务，视觉定位当前对象，本体感觉描述执行条件。执行“把杯子放进托盘”时，策略既要理解目标容器，也要根据杯柄与夹爪的相对位置选择接近方向。

9.1.2 泛化差距必须相对于明确的变化因素定义

令 $z = (z_o, z_s, z_l, z_e, z_d)$ 分别表示物体、场景、语言任务、机器人形态和动力学因素。训练环境分布与测试环境分布为 $p_{\text{tr}}(z, l)$ 和 $p_{\text{te}}(z, l)$。对固定策略 π，由真实环境与策略共同诱导轨迹分布 $P_z^\pi(\zeta \mid l)$，其中 ζ 表示完整轨迹。

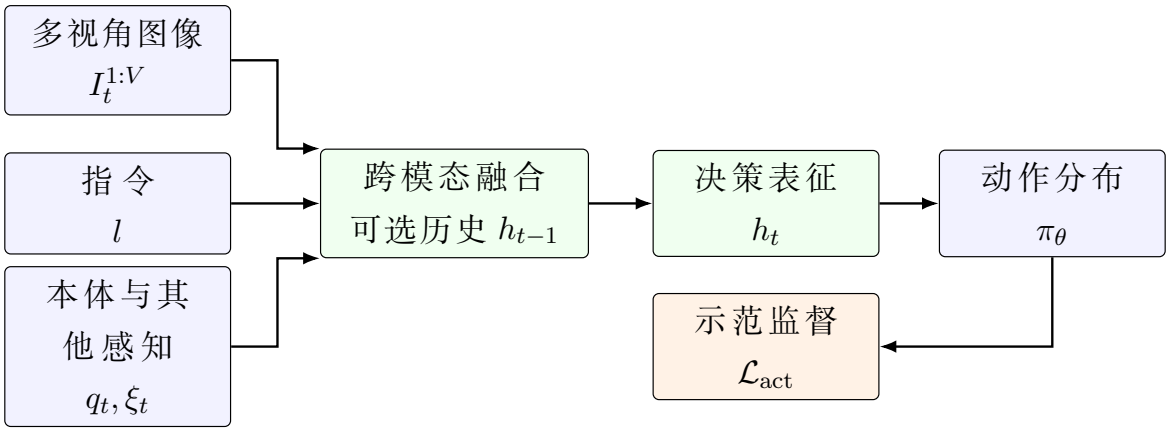


图 9.1: 视觉–语言–动作策略的信息流。视觉、语言与本体状态形成决策表征；历史输入进一步编码接触和任务阶段，动作监督将共享表征连接到执行目标。

定义 9.1.1: 具身操作的分布外泛化

定义任务风险及其变化为

$$\mathcal{R}_d(\pi) = \mathbb{E}_{(z,l)\sim p_d}\mathbb{E}_{\zeta\sim P_z^\pi(\cdot|l)}[\ell(\zeta, l)], \qquad d \in \{\text{tr}, \text{te}\}, \tag{9.1.3}$$

$$\Delta_{\text{gen}}(\pi) = \mathcal{R}_{\text{te}}(\pi) - \mathcal{R}_{\text{tr}}(\pi). \tag{9.1.4}$$

给定可接受风险 $\mathcal{R}_{\max}$ 与泛化差距阈值 ϵ，以 $\mathcal{R}_{\text{te}}(\pi) \le \mathcal{R}_{\max}$ 且 $\Delta_{\text{gen}}(\pi) \le \epsilon$ 衡量策略在指定偏移下的泛化能力。前者约束实际任务表现，后者约束环境变化带来的性能损失。

式 (9.1.3) 将策略纳入轨迹分布的生成过程，揭示了闭环控制中特有的误差传播机制。离线逐帧评测以记录好的观测为输入，预测动作不改变下一帧；在物理交互中，上一时刻的执行偏差却会改变下一时刻的观测。例如，抓取时偏离物体中心会改变搬运姿态，继而改变放置时的边缘对齐关系。策略由此进入专家示范较少覆盖的状态，产生随执行累积的协变量偏移。闭环测试通过真实动作与环境反馈测量这一过程；进一步按物体材质、几何尺度、相机视点或装配关系隔离测试环境，便能分析不同变化因素引起的风险增量。

9.1.3 动作参数化也是泛化机制的一部分

给定同一观测，多个抓点、绕行方向或放置姿态都可能正确。单点回归把这些示范压缩为一个向量，离散分类为不同候选分配概率，连续生成则直接学习动作或动作序列

表 9.2: 泛化维度、物理关系与评测对象。

变化因素	需要保持或相应改变的关系	评测对象
位置、视角与背景	对象移动时动作同步变化；背景变化时任务判断稳定	物理位移、真实视点与背景替换下的动作响应
对象与任务组合	新对象语义映射至当前实例、接触与容器	未见对象的接触选择与新关系组合的执行
机器人与夹爪	共享任务空间目标，适配坐标、频率和执行约束	平台特定控制量映射与目标平台成功率
摩擦、载荷与延迟	根据动作后果与反馈修正状态偏差	扰动后的恢复能力与长时程完成率

的条件分布。根据对连续性与多峰性的处理方式，动作空间的参数化形式可概括为

$$\text{单点回归:} \quad \hat{a} = f_\theta(h, l), \quad \mathcal{L}_{\text{MSE}} = \mathbb{E}\|a^\star - \hat{a}\|^2, \tag{9.1.5}$$

$$\text{密集分类:} \quad \pi_\theta(a_i \mid h, l) = \frac{e^{S_i}}{\sum_j e^{S_j}}, \quad \mathcal{L}_{\text{CE}} = -\log \pi_\theta(a^\star \mid h, l), \tag{9.1.6}$$

$$\text{连续生成:} \quad A_t \sim p_\theta(A_t \mid h_t, l). \tag{9.1.7}$$

例如，积木两端对应两个分离抓取模式：单点 MSE 回归趋向两端的加权平均，密集分类在两端保留独立概率峰，连续生成模型通过采样输出其中一个模式。混合密度回归、空间分类与连续残差的组合，也沿着这一思路组织多解动作。下面从密集分类入手，分析动作分布如何与几何关系共同决定泛化。

9.2 空间等变性与密集动作表示：以 Transporter Networks 为解剖样本

9.2.1 双位姿原语与条件动作分解

桌面上放着一块 L 形积木和一个配套凹槽。吸盘可以吸住长臂末端，也可以吸住转角附近；目标凹槽没有变化，末端的释放位置却必须随抓点改变。Transporter Networks 将这一物理依赖融入双位姿动作原语：高层网络预测抓取与放置两个关键端点，低层运动原语负责接近、吸附、抬升、搬运和释放 [1]。

设世界、夹爪和物体坐标系分别为 W, G, O。吸附稳定且搬运中不发生滑移时，物体相对夹爪的位姿 T_{GO} 保持恒定：

$$T_{WO} = T_{WG} T_{GO}, \qquad T^\star_{WG} = T^\star_{WO} T_{GO}^{-1}. \tag{9.2.1}$$

式 (9.2.1) 揭示了抓放动作的空间依赖：抓取改变相对变换 T_{GO}，末端就必须以对应位姿补偿，才能使物体抵达同一目标 $T^{\star}_{WO}$。例如，在保持方向的平面搬运中，抓点沿物体长臂移动 2 厘米，释放点也沿目标物体的对应方向移动 2 厘米。放置预测因此需要以抓取关系为条件。

完整双位姿原语属于 $SE(3) \times SE(3)$。在平面抓放配置中，高度由高度图与执行原语处理，抓取方向受原语约束，网络输出写为

$$a = (\mathbf{u}_p, b), \qquad \mathbf{u}_p = (r_p, c_p), \qquad b = (\mathbf{u}_d, k) = (r_d, c_d, k), \quad \vartheta_k = 2\pi k/K. \tag{9.2.2}$$

其中 k 是方向搜索索引。它与执行器偏航角的正负号由坐标约定决定。

如果为每一对抓取和放置候选建立联合评分，候选总数为

$$N_{\text{joint}} = (HW)(HWK) = H^2W^2K. \tag{9.2.3}$$

当 $H = 320, W = 160, K = 36$ 时，候选数量达到近千亿级，即 $N_{\text{joint}} \approx 9.4 \times 10^{10}$。仅以 32 位浮点数存储这张联合评分表就需要约 377 GB，联合动作张量成为主要的存储与计算负担。依据概率链式法则，以抓点为条件分解动作分布：

$$p(\mathbf{u}_p, b \mid I) = p(\mathbf{u}_p \mid I)\, p(b \mid \mathbf{u}_p, I). \tag{9.2.4}$$

采用级联搜索时，第一阶段评估约 5.1×10^4 个抓点并选定其中一个，第二阶段围绕该条件评估约 1.8×10^6 个放置候选。这样将近千亿级联合展开转化为两次密集评估。计算量的降低来自抓取条件的选择：保留前 B 个抓点时，搜索规模为 $HW + BHWK$；B 控制搜索覆盖与计算预算。

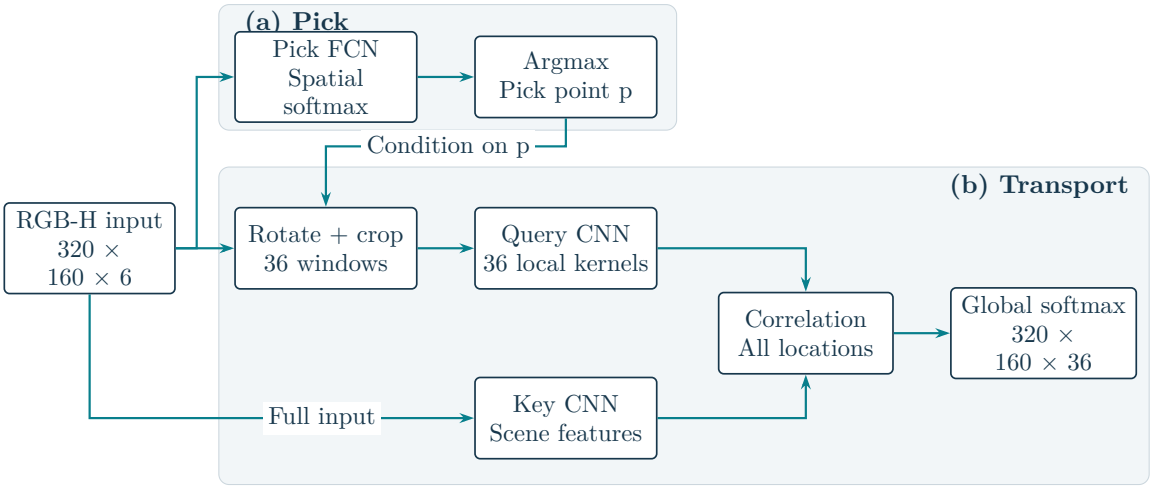


图 9.2: Transporter 的两阶段信息流。抓取分支给出坐标，查询分支围绕该点旋转并裁剪输入，键分支提取全景特征，两者通过互相关生成条件放置分布。教学重绘图来自配套技术解析 [3]，结构依据原论文与 Ravens 实现 [1, 2]。

部署时通常采用贪心解码：

$$\widehat{\mathbf{u}}_p = \arg\max_{\mathbf{u}_p} p(\mathbf{u}_p \mid I), \qquad \hat{b} = \arg\max_{b} p(b \mid \widehat{\mathbf{u}}_p, I). \tag{9.2.5}$$

联合最优则应比较每个抓点的 $p(\mathbf{u}_p \mid I)\max_b p(b \mid \mathbf{u}_p, I)$。抓取分支最高的点，未必具有最集中的后续放置分布。贪心方法用搜索范围换取速度；章节末的练习给出一个可手算的反例。

9.2.2 正交投影与空间等变性：把物理位移接到像素位移

在透视图像中，同一物体距离相机越远，占用的像素通常越少；相同的桌面位移也未必对应相同像素偏移。若直接把图像坐标作为动作坐标，网络还需学习位置相关的投影变形。Transporter 先利用 RGB-D 与标定参数构建俯视正交网格，将空间尺度规整到统一物理单位。

设透视图像坐标为 (u, v)，深度为 d，相机内参为 K_{cam}，则

$$\mathbf{x}_C = dK_{\text{cam}}^{-1}[u, v, 1]^\top, \qquad \mathbf{x}_W = R_{WC}\mathbf{x}_C + t_{WC}. \tag{9.2.6}$$

将点云栅格化到水平工作区，得到

$$c = \left\lfloor \frac{X - X_{\min}}{s_g} \right\rfloor, \qquad r = \left\lfloor \frac{Y - Y_{\min}}{s_g} \right\rfloor. \tag{9.2.7}$$

网格记录可见表面的颜色与高度，形成正交观测张量

$$I \in \mathbb{R}^{H \times W \times C_I}, \qquad C_I = C_{\text{rgb}} + C_{\text{height}}. \tag{9.2.8}$$

其中 C_{rgb} 与 C_{height} 分别为颜色和高度编码的通道数。[1] 固定配置使用 $s_g = 0.003125\,\text{m}$，$X \in [0.25, 0.75)\,\text{m}$，$Y \in [-0.5, 0.5)\,\text{m}$，形成 320×160 网格。

采用网格原点约定，逆映射为

$$X = X_{\min} + cs_g, \qquad Y = Y_{\min} + rs_g. \tag{9.2.9}$$

因而，向世界 X 正方向移动 31.25 毫米，对应列索引增加 10；向世界 Y 正方向移动相同距离，对应行索引增加 10。正交化使工作区内相同的物理位移对应相同的像素位移，为空间规则共享建立统一尺度。

定义 9.2.1: 空间等变性

对网格平移算子 $(\mathsf{T}_\delta I)(\mathbf{u}) = I(\mathbf{u} - \delta)$，若

$$\Phi(\mathsf{T}_\delta I) = \mathsf{T}_\delta \Phi(I), \tag{9.2.10}$$

[1] 本章配套 Ravens 实现将三通道 RGB 与重复堆叠的三通道高度图拼接，得到 $C_I = 6$。高度通道的重复属于张量编码方式；观测的物理来源为颜色与表面高度。

则称映射 Φ 对该平移等变。物体向右移动时，抓取响应也向右移动；这不同于输出保持不变的平移不变性。

性质 9.2.1: 步长一互相关的平移等变性

在无限离散网格上，对固定核 w，定义 $\Phi(I)(\mathbf{u}) = \sum_{\mathbf{v}} w(\mathbf{v}) I(\mathbf{u}+\mathbf{v})$，则

$$\Phi(\mathsf{T}_\delta I)(\mathbf{u}) = \sum_{\mathbf{v}} w(\mathbf{v}) I(\mathbf{u}+\mathbf{v}-\delta) \tag{9.2.11}$$

$$= \Phi(I)(\mathbf{u}-\delta) = (\mathsf{T}_\delta \Phi(I))(\mathbf{u}). \tag{9.2.12}$$

逐点非线性也与平移交换，故这类算子的组合保留该性质。

这一结构把同一局部规则复用到不同位置：网络不必为左上角和右下角分别学习一套抓取判据。若查询编码对同步移动的图像与抓点给出相同局部模板，键编码又保持等变，则条件评分也随场景平移：

$$S_{\mathsf{T}_\delta I}(\mathbf{u}+\delta, k \mid \mathbf{u}_p+\delta) = S_I(\mathbf{u}, k \mid \mathbf{u}_p). \tag{9.2.13}$$

式中对**完整场景和抓取条件**施加同一平移。例如，积木与凹槽一起向右移动十格，查询模板保持一致，相关峰也向右移动十格；积木相对凹槽的几何关系得到保留。

实际网络中的 8 倍下采样会区分不同采样相位：输入平移 1 像素，低分辨率网格发生错位；平移 8 像素，采样位置恢复对应。旋转插值、补零和视野截断也参与空间映射。第 9.6 节将以采样算子和真实检查点分析这些变化。

9.2.3 均值陷阱与密集评分图

对称积木的两端都能抓取，托盘的多个空位都能放置。这种多模态动作分布对应**同一观察下彼此分离的合法接触点**。若用单个向量回归这些位置，训练目标可能把不同可行解平均成不可行解。

令示范动作标签为 y，$\mu(I) = \mathbb{E}[y \mid I]$。将 $y - f(I)$ 拆为 $y - \mu + \mu - f$，平方展开后，交叉项因 $\mathbb{E}[y-\mu \mid I] = 0$ 消失：

$$\mathbb{E}[\|y - f(I)\|^2 \mid I] = \mathbb{E}[\|y - \mu(I)\|^2 \mid I] + \|\mu(I) - f(I)\|^2. \tag{9.2.14}$$

第一项与预测无关，第二项在 $f(I) = \mu(I)$ 时最小。因此，平方损失的最优单点是**按示范频率加权的条件均值**。当两个抓点等频出现时，最优输出落在二者中点；出现频率偏向一侧时，最优输出也向该侧移动。

例 9.2.1: 四接触岛：损失最优而动作无效

在 41×41 网格中，四个合法接触岛的圆心分别为 $(10,10),(30,10),(10,30),(30,30)$，半径均为 3。同一输入下，四个圆心以相同频率作为标签。MSE 的最优输出为

$$\bar{y}=\tfrac{1}{4}\big[(10,10)+(30,10)+(10,30)+(30,30)\big]=(20,20). \tag{9.2.15}$$

该点处于中央非法区域。若改为 1681 个自由 logit 的全图分类，经验目标分布在四个圆心各有 1/4 概率；其交叉熵下确界为 $\log 4\approx 1.386$。配套算例优化后，每个峰约占 24.98%，合法区域总概率约为 99.92% [3]。

图 9.3 将这一差异直接呈现在收敛过程与空间分布中：单点回归的损失平稳下降并趋于最优值（图 c），最终预测却落在中央非法区域（图 a）；全图分类的交叉熵趋近 $\log 4$（图 d），同时在四个接触岛上形成分离的概率峰（图 b），通过 $\arg\max$ 选择其中一个峰。图 c 使用归一化坐标 $x'=x/20-1$、$y'=y/20-1$，四个圆心到均值的平方距离均为 0.5，故曲线趋近 0.5。两种目标都得到充分优化，动作有效性的差异来自输出表征对多解结构的处理方式。

密集评分图令每个候选位置拥有一个 logit S_i，再通过共享分母构成动作分布 $V_i=e^{S_i}/\sum_j e^{S_j}$。不同示范为相应候选积累概率质量，推理再从分离的峰中选择一个动作。由此，多解性被保留在概率分布中，执行阶段则输出明确的单次接触位置。

9.2.4 视觉空间搬运：动态查询核与深层互相关

抓点确定之后，策略需要寻找与被抓物体在任务上相容的空间位置。红色积木和深色凹槽在 RGB 空间差异很大，却可能因形状匹配而在学习特征中形成高相关响应。Transporter 用两个独立编码器学习这种相容性 [1,2]。

固定 Ravens 版本的查询路径先旋转输入、再裁剪、后编码。设 $\widetilde{I}$ 是填充后的观察，则

$$I_{p,k}=\mathcal{C}_{\mathbf{u}_p}\mathcal{R}_{\mathbf{u}_p,\vartheta_k}(\widetilde{I})\in\mathbb{R}^{C\times C\times C_I}, \tag{9.2.16}$$

$$Q_{p,k}=\psi_\gamma(I_{p,k})\in\mathbb{R}^{C\times C\times D},\qquad F=\phi_\beta(\widetilde{I})\in\mathbb{R}^{H'\times W'\times D}. \tag{9.2.17}$$

查询编码器 ψ_γ 读取抓点周围的局部几何，键编码器 ϕ_β 读取全工作区。查询边长 C 决定模板覆盖范围，特征通道数 D 决定每个位置的编码维数，方向数 K 决定离散旋转的分辨率。

查询特征被直接解释为**由当前输入生成的动态卷积核**。固定抓点与方向，用 $\star$ 表示不翻转核的互相关：

$$S(r,c,k\mid\mathbf{u}_p,I)=(Q_{p,k}\star F)(r,c)=\sum_{i=0}^{C-1}\sum_{j=0}^{C-1}\sum_{d=1}^{D}Q_{p,k}(i,j,d)F(r+i,c+j,d). \tag{9.2.18}$$

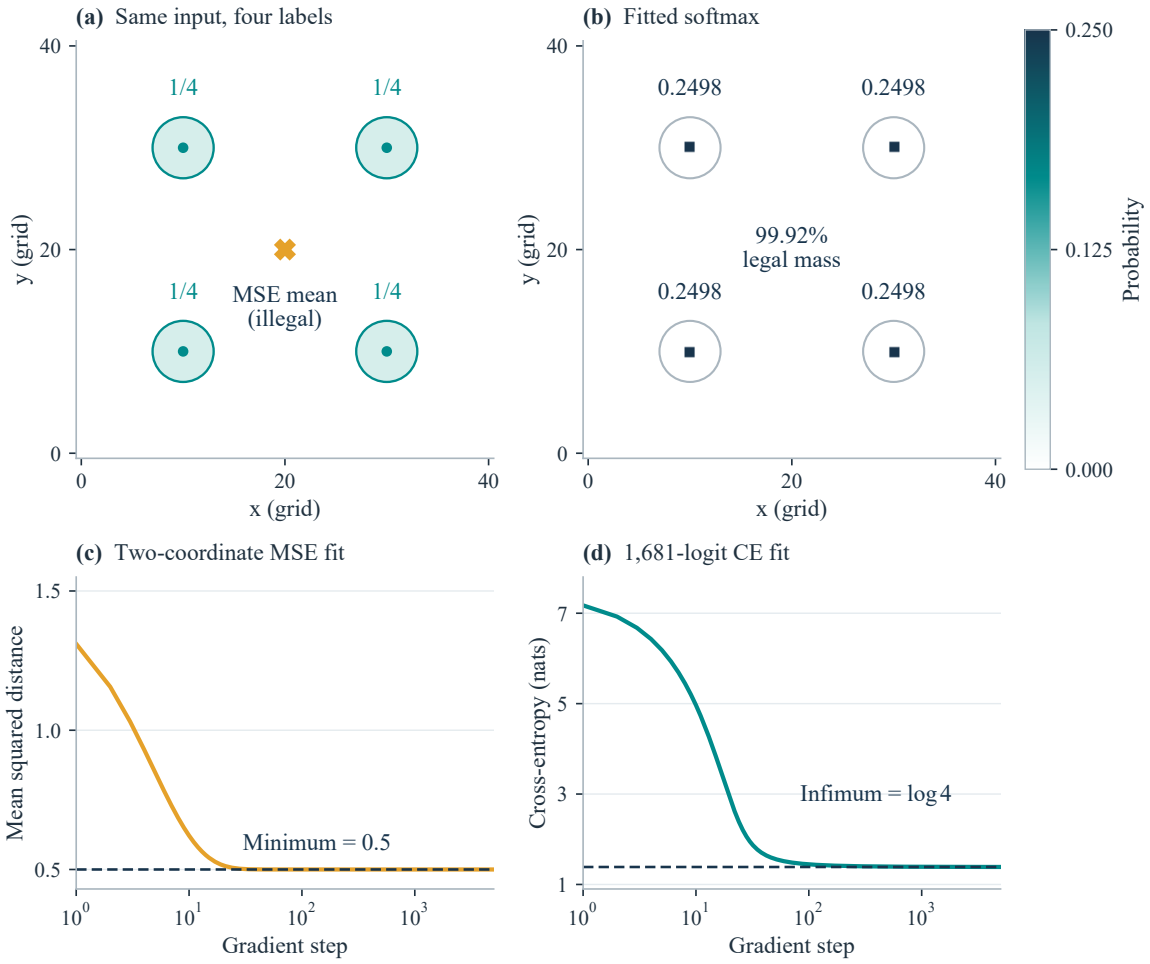


图 9.3: 四接触岛的合成算例 [3]。固定输入下，分别优化二维坐标与全图自由 logits。(a) 四个合法区域与中央回归均值；(b) 分类得到的分离概率峰；(c) 归一化坐标的 MSE 曲线；(d) 全图分类的交叉熵曲线。

式中 (r, c) 先按键窗口左上角计数；回到动作坐标时要扣除填充偏移。通道内积衡量一对位置的特征相容性，空间求和整合整块模板的匹配证据。

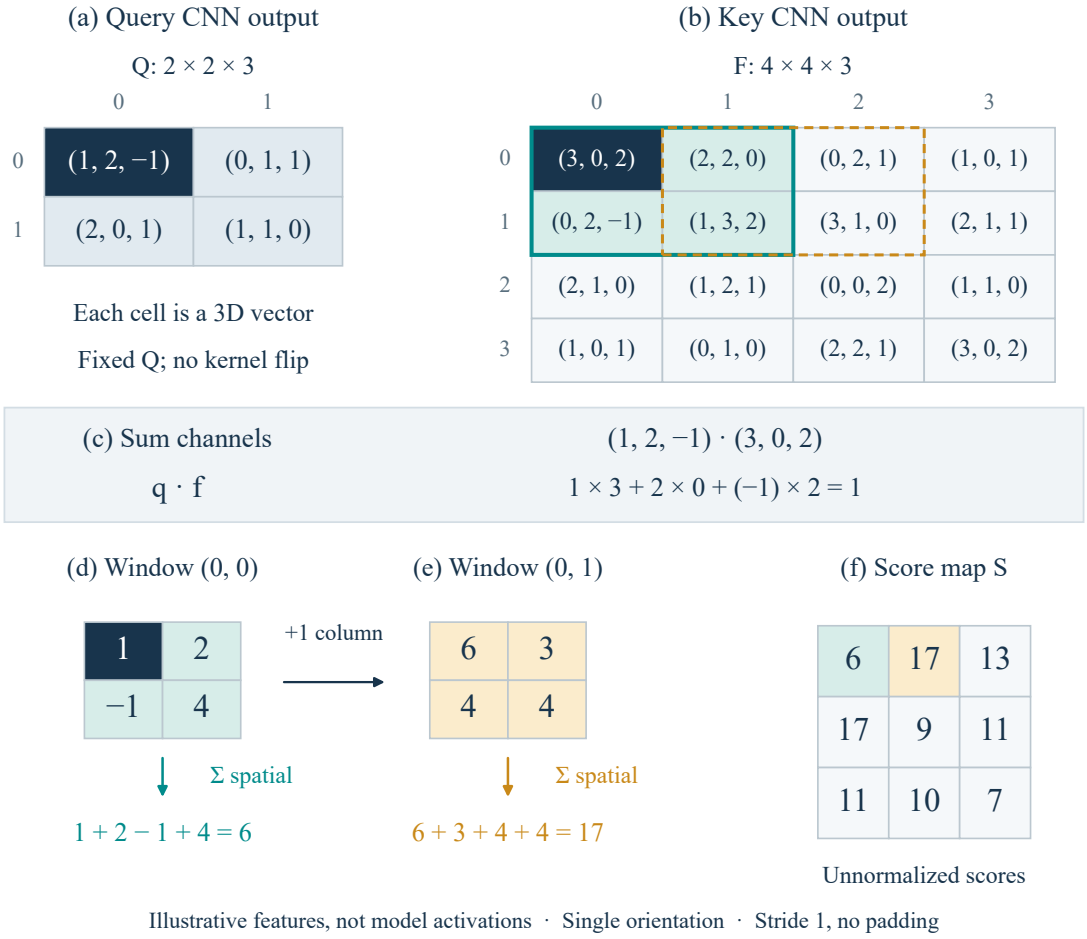


图 9.4: $2 \times 2 \times 3$ 查询与 $4 \times 4 \times 3$ 键特征的互相关算例 [3]。每格是三通道向量；先按通道求内积，再在 2×2 窗口内求和。九个窗口生成 3×3 未归一化评分图。

以图 9.4 为例，左上位置的通道内积为

$$\langle (1, 2, -1), (3, 0, 2) \rangle = 1 \times 3 + 2 \times 0 - 1 \times 2 = 1. \tag{9.2.19}$$

第一个窗口的四项贡献是 $\left[\begin{smallmatrix} 1 & 2 \\ -1 & 4 \end{smallmatrix}\right]$，故 $S(0,0) = 6$；向右滑动一格，四项贡献变为 $\left[\begin{smallmatrix} 6 & 3 \\ 4 & 4 \end{smallmatrix}\right]$，故 $S(0,1) = 17$。第二个位置积累了更高的特征相容评分，随后与其他位置共同参与归一化。

实现时，对输入边缘进行填充，使查询窗口能够覆盖工作区边界；不同旋转的查询核与同一键特征批量相关，形成 $H \times W \times K$ 评分体。[2]

计算收益来自两种共享：键特征只需提取一次，查询核在所有候选位置复用。同一抓点下的密集相关，替代了为每个放置姿态独立编码图像。其代价随空间分辨率、方向数和查询尺寸增加。

[2]配套配置取 $C = 64, D = 3, K = 36$。$320 \times 160 \times 6$ 输入四周各填充 32 格，形成 $384 \times 224 \times 6$；查询特征补零至 65×65，与 $384 \times 224 \times 3$ 键特征相关后得到 $320 \times 160 \times 36$ 评分体。

9.2.5 全局 Softmax：梯度竞争与隐式难负例加权

一个示范只给出一个抓放答案，网络却需要降低大量混淆候选的响应。全局 Softmax 通过统一分母，把位置与方向置于同一个竞争空间。将 $H \times W \times K$ 评分展平，候选数为 N，示范索引记为 $j^\star$：

$$V_i = \frac{e^{S_i}}{\sum_{j=1}^{N} e^{S_j}}, \qquad Y_i = \mathbb{I}[i = j^\star], \qquad \mathcal{L} = -\log V_{j^\star} = -S_{j^\star} + \log \sum_{j=1}^{N} e^{S_j}. \tag{9.2.20}$$

对任意 S_m 求导，分子中只有第 m 项保留：

$$\frac{\partial \mathcal{L}}{\partial S_m} = -\delta_{m,j^\star} + \frac{1}{\sum_j e^{S_j}} \frac{\partial}{\partial S_m} \sum_j e^{S_j} \tag{9.2.21}$$

$$= -Y_m + \frac{e^{S_m}}{\sum_j e^{S_j}} = V_m - Y_m. \tag{9.2.22}$$

示范点得到负梯度 $V_{j^\star} - 1$，其余候选得到正梯度 V_m。直接更新 logits 时，前者上升、后者下降。共享网络通过链式法则汇总各位置的误差信号：

$$\nabla_\theta \mathcal{L} = \sum_m (V_m - Y_m) \nabla_\theta S_m. \tag{9.2.23}$$

其中 $\nabla_\theta S_m$ 将空间候选的竞争传递到卷积特征；同一参数由多个位置共同更新，形成跨位置共享的匹配规则。

性质 9.2.2: 全局分类梯度的零和性质

若标签分布满足 $\sum_m Y_m = 1$，则

$$\sum_{m=1}^{N} \frac{\partial \mathcal{L}}{\partial S_m} = \sum_m V_m - \sum_m Y_m = 0. \tag{9.2.24}$$

单个示范点的提升量与其余候选的总抑制量在 logit 梯度层面相抵。例如，示范点概率为 0.2 时，其梯度为 -0.8，其余候选的正梯度之和为 0.8。

对于未被选中的候选，$|\partial \mathcal{L}/\partial S_m| = V_m$。概率很小的背景点获得较小梯度；概率较高的混淆候选获得较大梯度。这构成一种**隐式难负例加权**。One-hot 标签记录每次示范的选择；当另一合法抓点在后续示范中被选中时，它也获得对应的概率提升。

若同一条件下的示范分布为 $q^\star$，则期望梯度为

$$\mathbb{E}_Y[\nabla_S \mathcal{L}] = V - q^\star. \tag{9.2.25}$$

期望梯度在 $V = q^\star$ 时为零：每次示范推高一个候选，多次示范共同确定各峰的相对质量。四接触岛中的四个圆心等频出现，因此经验最优分布在每个圆心分配 1/4 的概率，与图 9.3 的收敛结果相对应。

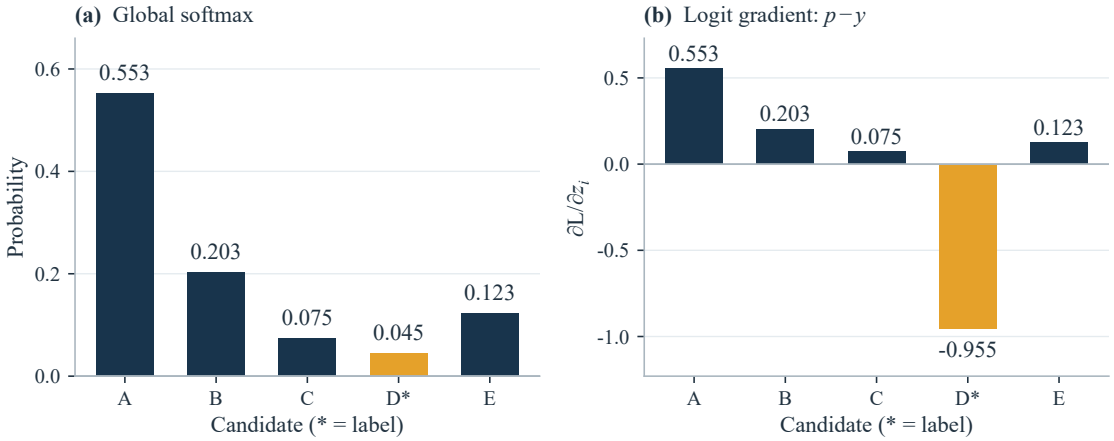


图 9.5: 五个自由 logits 的全局 Softmax 梯度校验 [3]。唯一标签为 D；左为概率，右为 logit 梯度。中心有限差分的最大绝对误差小于 2.45×10^{-10}。

两阶段行为克隆的总损失可写为

$$\mathcal{L}_{\text{act}}^{\text{TN}} = -\log p_\alpha(\mathbf{u}_p^\star \mid I) - \log p_{\beta,\gamma}(b^\star \mid \mathbf{u}_p^\star, I). \tag{9.2.26}$$

训练用示范抓点构造查询，部署用预测抓点。抓取位置偏移会改变查询窗口中的物体局部，进一步移动条件相关峰。第 9.6 节通过同一场景下的多抓点实验，观察这种级联变化能否保持刚体补偿关系。

本节要点

Transporter 将四个关系写入计算结构：正交网格统一物理尺度，卷积共享复用空间规律，局部查询编码抓放依赖，全图分类容纳分离动作峰。下一节讨论这些关系如何与开放语义和高维控制结合。

9.3 泛化范式的演进脉络：从几何先验到多模态基础模型

9.3.1 空间规则共享与任务结构

如果训练数据只覆盖桌面的少数位置，空间共享便能把已学会的局部操作规则复用到其他位置。Transporter 原论文在 100 条示范下比较了多种策略结构，表 9.3 列出四类任务的结果。

套件装配要求在对象与槽位之间建立精确的形状对应。条件相关直接在共享坐标系内比较局部几何，使空间关系成为计算过程的一部分。GT-State MLP 则从状态向量中学习这些对应，其学习负担由输入表示和网络结构共同决定。碎物清扫还包含接触后物体集合的重新分布，动作效果同时依赖推扫方向与接触动力学；该任务体现了从静态形状匹配向交互过程建模的需求。

表 9.3: Transporter 原论文表 2 的四任务摘录 [1]。训练规模均为 100 条示范回合，数值为平均任务得分的百分数；ConvMLP 使用混合密度网络（MDN）。

任务	Transporter	Form2Fit	ConvMLP	GT-State MLP
积木插入	100	23	6	96
套件装配	90.4	24.2	0.2	1.2
汉诺塔	97.3	3.7	1.9	6.1
碎物清扫	71.5	26.7	44.9	63.2

表中的 ConvMLP 使用混合密度网络，以多个分布分量表达多解；Transporter 则把动作候选组织到共享空间坐标上，用卷积和相关复用局部规律。这对应两项互补能力：**输出层保留多少动作模式，以及特征层如何组织几何关系**。表中平均任务得分统计各回合获得的奖励，部分完成的任务也贡献相应得分。

深度与标定把观察映射到统一网格，平面分类则承担位置和偏航搜索。原论文的 $SE(3)$ 扩展保留这一搜索结构，再从相关特征回归高度、俯仰和翻滚 [1]。更复杂的操作进一步提出两项要求：动作位置需要扩展到三维空间，任务目标需要由开放语义指定。几何表示与语义数据由此成为后续研究的两条主要线索。

9.3.2 两条主线：空间结构延续与语义数据扩展

空间结构延续。 几何相容性可以找到匹配槽位，而“把红色积木放进左侧容器”还要求从多个几何可行对象中选择指定实例。围绕这一矛盾，Shridhar、Manuelli、Fox 及其合作者的系列工作逐步扩展空间策略。CLIPort 引入语义与空间双通路：预训练 CLIP 提供“操作什么”的语义条件，Transporter 式空间通路处理“在哪里操作”，语言由此参与抓取与放置候选的评分 [8]。

当任务转向抽屉、铰接物体或立体装配，位置候选需要显式覆盖高度维。PerAct 将三维观测组织为体素，用 Perceiver 融合语言与空间信息，直接在三维工作区预测动作位置，并估计旋转与夹爪状态 [9]。这把动作定位从平面像素扩展为有几何参照的三维候选。

新的瓶颈随之转移到分辨率与存储：每轴划分 N 格的稠密体素包含 N^3 个单元，三个方向各加倍分辨率便需要八倍单元。RVT 改用点云的虚拟多视图投影，将三维位置证据汇聚到若干二维视图；固定 M 个视图时，图像单元数随 MN^2 增长，再通过视图间信息融合恢复空间定位 [10]。RVT-2 进一步以粗到细定位等设计兼顾局部精度与推理效率 [11]。从平面网格到体素再到多视图，变化的是空间表示，持续保留的是动作与几何参照的绑定。

语义与数据扩展。 另一条路线优先扩大策略可利用的经验。Google Robotics/DeepMind 的 RT-1 以多任务机器人示范学习语言条件控制，使不同任务共享感知与动作模型 [7]。机器人采集覆盖的对象和语言表达有限，RT-2 因而将网络图文预训练与动作 token 学习结合，用视觉语言知识为机器人操作提供更广的语义条件 [4]。

跨任务共享进一步引出跨平台的数据异构问题：相同的“抬起物体”对应不同相机、夹爪和控制量。Open X-Embodiment/RT-X 汇集多机构、多机器人数据，探索统一训练中的经验迁移 [6]。OpenVLA 则提供基于预训练视觉语言骨干和混合机器人数据的开放策略及适配方法，使通用初始化能够继续用于目标机器人微调 [5]。这条路线从共享任务经验走向共享语义与跨平台经验，其核心是把扩大的知识覆盖转化为目标平台上的可执行动作。

表 9.4: 空间结构与语义数据两条研究路线。箭头表示技术问题与表示形式的推进。

对照维度	空间结构路线	语义数据路线
代表线索	Transporter → CLIPort → PerAct → RVT/RVT-2	RT-1 → RT-2；Open X/RT-X 与 OpenVLA 扩展数据及开放模型
信息通路	标定观测进入网格、体素或多视图；动作位置绑定几何参照	图像与语言进入预训练骨干；机器人数据约束动作输出
主要收益	空间规则共享，减少有限示范中的几何学习负担	语义覆盖与多任务经验复用，扩大可理解的对象和指令范围
主要代价	深度、标定、空间分辨率与候选搜索成本	训练数据、模型容量、动作解码与部署时延
适用条件	表示几何与实际操作空间相匹配	语义知识能落到当前证据与可执行技能

两条路线共同决定**哪些几何关系由结构直接规定，哪些语义与操作关系由数据学习**。空间策略可以引入语义骨干，通用模型也可以加入几何锚点与局部监督。它们在精细接触处汇合：开放语义负责指定对象，局部表征负责保留执行所需的边缘、姿态与间隙。

9.3.3 从四接触岛到高维动作：分类思想与连续生成

四接触岛揭示的均值陷阱，在现代 VLA 中扩展到高维动作序列。例如，机械臂从障碍左侧或右侧绕行都可到达目标，两条合法轨迹的逐点平均却可能穿过障碍。动作表征需要保留这些分离模式，再从中选择一条可执行轨迹。

Transporter 在 $H \times W \times K$ 空间维持密集概率。若改为对 d_a 个连续自由度分别划分 B 个区间，再为所有组合建立联合网格，候选数将增长为

$$N_{\text{grid}} = B^{d_a}. \tag{9.3.1}$$

例如，7 个动作自由度各划分 100 个区间，联合网格就包含 10^{14} 个候选。高维操作由此需要更紧凑的动作分布参数化。自回归离散化将联合分布拆成条件序列，条件扩散则通过连续去噪生成动作样本。

离散动作 token：将联合网格分解为序列。 RT-2 将动作分量离散编码为 token 序列，并与视觉语言任务共同训练 [4]。令 $b_1, \dots, b_M$ 为一组动作编码，则

$$p_\theta(b_{1:M} \mid h, l) = \prod_{j=1}^{M} p_\theta(b_j \mid b_{<j}, h, l), \qquad \mathcal{L}_{\text{tok}} = -\sum_{j=1}^{M} \log p_\theta(b_j^\star \mid b_{<j}^\star, h, l). \tag{9.3.2}$$

每步输出有限候选，同时借助前缀保留分量依赖。例如，预测完平移分量后，旋转分量继续以此前的选择为条件，形成一致的动作编码。区间宽度决定量化精度，序列长度决定逐步解码开销。

动作扩散：在连续空间逐步生成动作块。 Diffusion Policy 将动作序列作为条件去噪的生成对象，并以滚动时域执行其中一段 [12]。令示范动作块为 $A^{(0)}$，其带噪版本及训练目标为

$$A^{(\tau)} = \sqrt{\bar{\alpha}_\tau} A^{(0)} + \sqrt{1 - \bar{\alpha}_\tau}\varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, \mathbf{I}), \tag{9.3.3}$$

$$\mathcal{L}_{\text{diff-act}} = \mathbb{E}_{\tau,\varepsilon} \| \varepsilon - \varepsilon_\theta(A^{(\tau)}, \tau, h_t) \|^2. \tag{9.3.4}$$

平方误差在这里监督的是给定带噪动作与观察条件的噪声预测。不同带噪样本对应不同的局部去噪方向，多步反向过程把它们逐渐推向相应动作模式。对于绕障任务，采样结果可以分别收敛到左绕或右绕轨迹；滚动时域执行再根据新观察修正后续动作。去噪步数与动作块长度共同决定计算开销和反馈频率。

本节要点

输出分布与视觉表征是两个互补问题。密集分类、动作 token 与扩散决定“能表达哪些动作”；局部几何与任务 grounding 决定“依据哪些证据选择动作”。精细操作需要二者共同保留可行接触模式及其视觉依据。

9.4 任务相关视觉 Grounding：显式几何对齐与隐式表征塑形

9.4.1 从注意力权重到任务相关证据

在窄口放置中，语言识别负责找到容器，可靠动作还需要容器边缘、物体姿态与夹爪间隙。若视觉编码只保留“这里有一个碗”，动作头就难以恢复毫米级的接触关系。任务相关视觉 grounding 要解决的，正是**如何把任务意图落到当前可操作的局部证据**。

设视觉 token 为 $x_{t,1:N}$，语言、本体与历史条件记为 $\chi_t = (l, q_t, h_{t-1})$，注意力权重可写为

$$\alpha_{t,i} = \frac{\exp\Big(q(\chi_t)^\top k(x_{t,i})/\sqrt{d}\Big)}{\sum_j \exp\Big(q(\chi_t)^\top k(x_{t,j})/\sqrt{d}\Big)}. \tag{9.4.1}$$

该权重决定当前层如何混合不同位置的值向量，后续残差与网络层继续加工这些信息。注意力热图显示信息聚合的位置，区域替换实验则测量这些位置对最终动作的影响。

定义 9.4.1: 区域依赖与任务相关性

将区域 R 替换后的观察记为 $I_t^{\setminus R}$。模型对该区域的依赖可用动作分布差异诊断：

$$\mathrm{Rel}_\pi(R; t) = D\Big(\pi_\theta(\cdot \mid I_t, \chi_t), \pi_\theta(\cdot \mid I_t^{\setminus R}, \chi_t)\Big). \tag{9.4.2}$$

其中 D 可取离散动作分布的总变差距离。区域依赖描述“替换后策略改变多少”，任务相关性描述“该区域如何影响可行动作或回报”。例如，更换桌布会改变一个依赖背景的策略，却保持抓放几何不变；移动容器边缘则同时改变视觉证据与合法放置范围。将动作变化与任务几何联合观察，可以区分这两种依赖。

相关区域随阶段变化：接近时需要目标与夹爪，抓取时需要接触点，放置时需要容器边缘与路径障碍。因此，任务相关区域可以由多个局部共同组成。

9.4.2 显式 grounding：将定位结果接入策略

显式路线把目标定位作为可检查的中间变量：

$$m_t = G_\psi(I_t, l), \qquad a_t \sim \pi_\theta(\cdot \mid I_t, m_t, l, q_t). \tag{9.4.3}$$

RoboGround 使用 grounding 掩码传递对象与放置区域信息；ECoT 则以子任务、边界框和末端位置等中间推理连接感知与动作 [13,14]。定位结果既能引导策略，也便于人工核查。

若保留中间结果的不确定性，复合策略可写为

$$p(a_t \mid I_t, l, q_t) = \sum_{m_t} p_\theta(a_t \mid I_t, m_t, l, q_t) p_\psi(m_t \mid I_t, l). \tag{9.4.4}$$

部署中常以一个估计 $\hat{m}_t$ 代替求和，以一次定位连接一次动作决策。将掩码作为附加通道时，策略同时读取区域提示与原图；将掩码用于乘性屏蔽或裁剪时，所选区域直接决定后续模块的输入范围。两种连接方式分别对应信息提示与信息筛选。

9.4.3 Transporter：在查询通路中构造局部信息约束

Transporter 的抓点具有双重角色：它既是执行器接触位置，也是查询窗口的几何锚点。固定抓点和旋转候选，式 (9.2.17) 先从输入提取局部张量，再运行查询 CNN。网

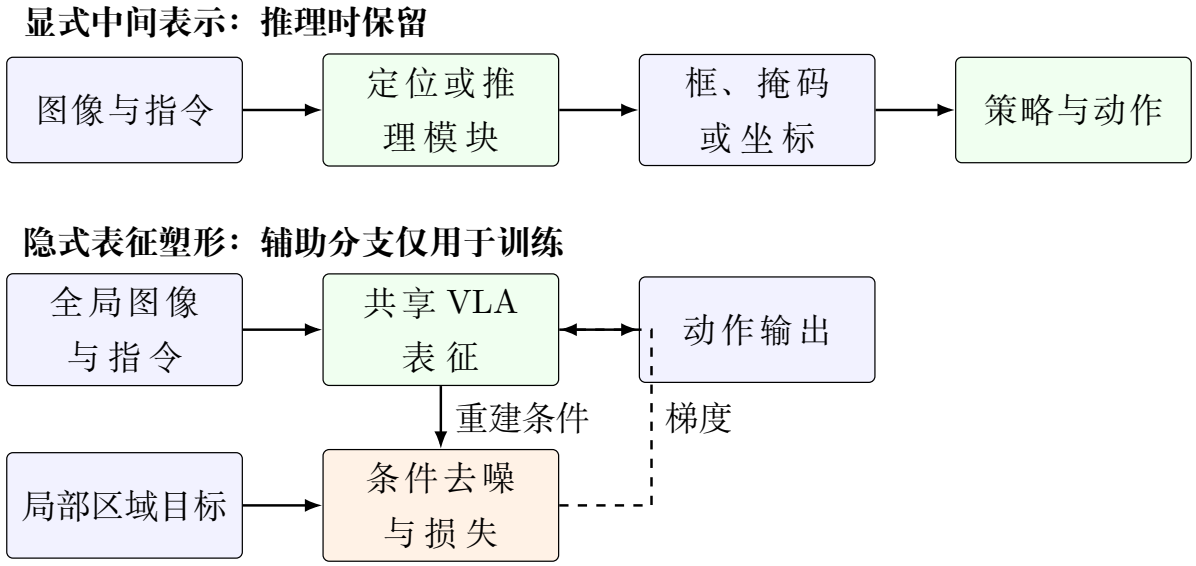


图 9.6: 显式与隐式 grounding 的信息流。上图以定位结果指导动作；下图以局部重建损失更新共享表征。虚线表示反向梯度，其余箭头表示前向数据流。

络只能用进入该张量的像素构造查询核。

令 $\mathcal{R}^{\mathrm{in}}_{p,k}$ 为第 k 个旋转裁剪在原输入中的采样支撑集，包含插值使用的邻域。对固定条件有

$$Q_{p,k} = \psi_\gamma(\mathcal{C}_{\mathbf{u}_p}\mathcal{R}_{\mathbf{u}_p,\vartheta_k}\widetilde{I}), \qquad \frac{\partial Q_{p,k}}{\partial I(\mathbf{u})} = 0, \quad \mathbf{u} \notin \mathcal{R}^{\mathrm{in}}_{p,k}. \tag{9.4.5}$$

固定条件下，裁剪外像素到**查询特征**的导数恒为零，局部信息范围由计算图直接规定。与此同时，全图键分支编码目标槽位与场景上下文，两条通路通过相关算子共同决定放置评分。

窗口尺寸决定查询核可利用的物体范围：较小窗口集中编码接触附近的边缘，较大窗口纳入更多物体部件及周围结构。例如，抓住长条物体一端时，窗口可能仅包含端部；增大窗口便能将另一端的形状与朝向纳入模板。抓点偏移同样通过改变裁剪内容影响后续相关响应。

Ravens 实现以示范抓点训练放置分支，以离散 $\arg\max$ 选择部署时的抓点，两个阶段分别接受对应标签的监督。若将抓点改为连续采样坐标，可用双线性插值计算裁剪结果对坐标的导数，让放置损失进一步优化窗口位置。这体现了选点方式对跨阶段梯度连接的作用。

9.4.4 ReconVLA：以局部重建塑形共享动作表征

ReconVLA 将局部信息约束移到训练目标中。策略仍接收全局图像与指令，训练阶段额外要求共享表征支持当前操作区域的重建 [15]。对于窄口放置，动作监督告诉网络“往哪里移动”，局部重建则要求表征保留碗口、物体边缘等可见细节。

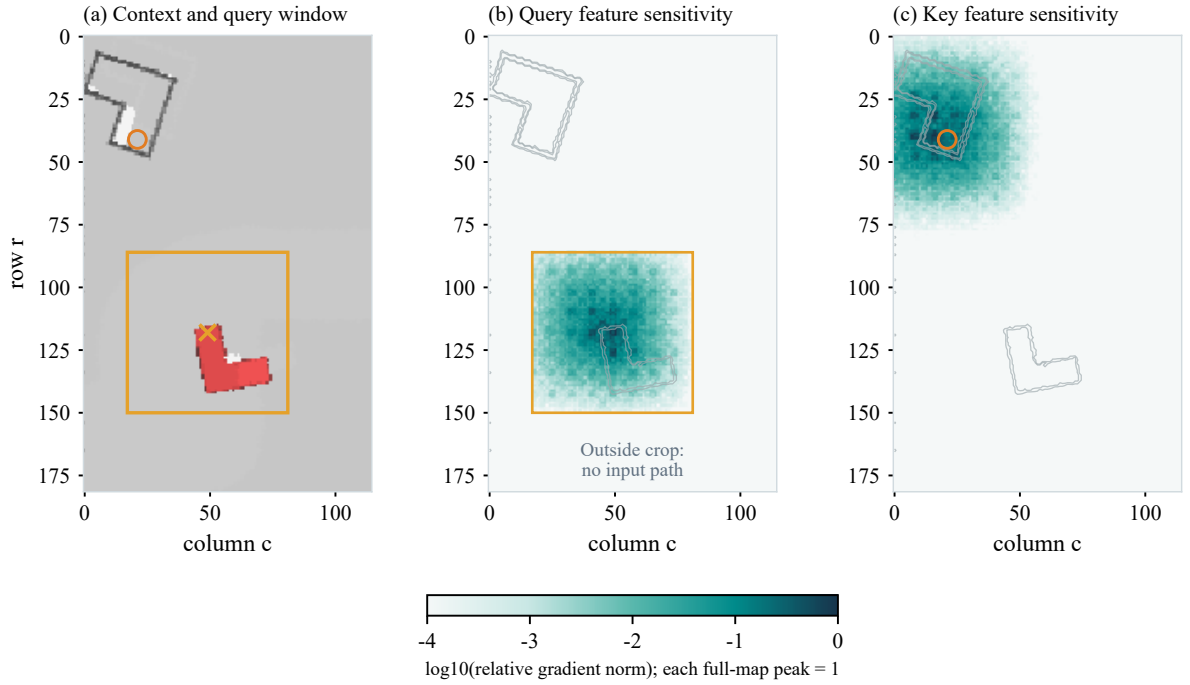


图 9.7: 查询与键特征的局部敏感度 [3]。(a) 场景与未旋转 64×64 查询框；(b) Query 中心特征平方范数对输入的梯度范数；(c) 所选放置位置的 Key 特征对应梯度。每张图独立按峰值归一化，显示 $\log_{10}$ 相对梯度，用于观察各自的空间支撑。Query 框外梯度为结构性零。

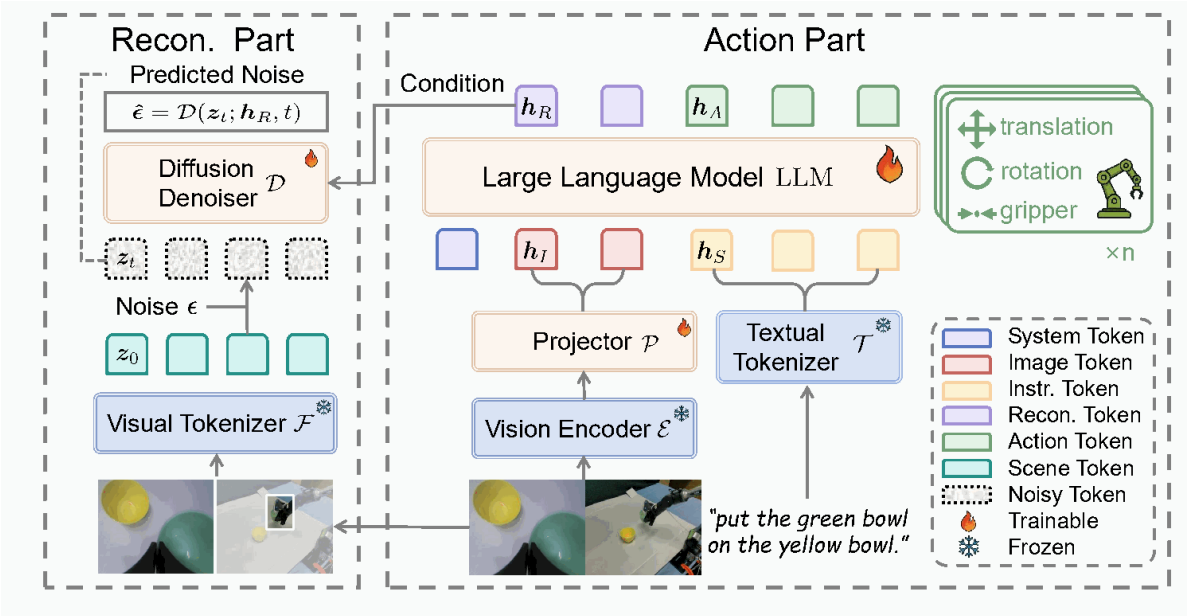


图 9.8: ReconVLA 网络结构，引自 Song 等原论文图 3 [15]。动作分支与重建分支共享条件表征；局部区域进入训练期去噪目标。图中的冻结与可训练标记按原文保留。

令当前注视区域为 R_t，通过视觉自编码器得到局部潜变量

$$z_0 = \mathcal{E}_{\text{vae}}(I_t|_{R_t}), \qquad z_\tau = \sqrt{\bar{\alpha}_\tau} z_0 + \sqrt{1-\bar{\alpha}_\tau}\varepsilon. \tag{9.4.6}$$

由全局输入得到重建条件 $c_t = g_\theta(I_t, l)$，去噪器预测加入的噪声。总训练目标为

$$\begin{aligned} \mathcal{L}_{\text{RV}} &= \mathcal{L}_{\text{act}} + \lambda_{\text{rec}}\mathcal{L}_{\text{rec}}, \\ \mathcal{L}_{\text{act}} &= -\sum_j \log p_\theta(b_j^\star \mid b_{<j}^\star, I_t, l), \\ \mathcal{L}_{\text{rec}} &= \mathbb{E}_{\tau,\varepsilon}\|\varepsilon - D_\phi(z_\tau, \tau, c_t)\|^2. \end{aligned} \tag{9.4.7}$$

论文还将指令 token 放在图像 token 之前，使因果注意力下的视觉表征能够读取任务条件。区域标注决定重建什么，任务条件决定同一画面中的哪些信息应进入共享表示。

从梯度通路看，辅助目标对共享参数的作用为

$$\nabla_\theta \mathcal{L}_{\text{RV}} = \nabla_\theta \mathcal{L}_{\text{act}} + \lambda_{\text{rec}} \left(\frac{\partial c_t}{\partial \theta}\right)^\top \nabla_{c_t}\mathcal{L}_{\text{rec}}. \tag{9.4.8}$$

重建梯度沿 $D_\phi \to c_t \to \theta$ 回传，将恢复局部细节的需求写入共享视觉表示。训练完成后移除辅助去噪分支，部署时由共享表征直接生成动作。

局部几何通过共享参数同时服务于动作与重建，两种监督的协同程度可以由梯度内积分析。用 $g_a = \nabla_\theta \mathcal{L}_{\text{act}}$、$g_r = \nabla_\theta \mathcal{L}_{\text{rec}}$ 表示两项梯度，在小步长 η 下，一步联合更新的一阶展开为

$$\mathcal{L}_{\text{act}}(\theta - \eta(g_a + \lambda g_r)) \approx \mathcal{L}_{\text{act}}(\theta) - \eta\|g_a\|^2 - \eta\lambda\langle g_a, g_r\rangle. \tag{9.4.9}$$

内积为正时，辅助梯度增加该步动作损失的下降量；为负时，两种目标竞争更新方向。例如，取 $g_a = (1,0)$、$g_r = (1,1)$、$\lambda = 0.5$，一阶下降量由 η 增至 1.5η；将 g_r 改为 $(-1,1)$，下降量则变为 0.5η。重建碗口边缘与对齐动作共享几何信息时，二者有机会形成协同；重建区域中大量无关纹理则可能占用更新预算。区域定义与 λ 因而共同控制辅助监督的作用。

9.4.5 核心对照：前向硬选择与反向软塑形

Transporter 与 ReconVLA 回答同一个问题：如何让动作依据局部关键证据？前者在**前向通路**中规定查询可读取的区域，后者在**反向监督**中要求表征支持局部恢复。表 9.5 从区域定义、信息通路与梯度连接三个层面比较这些机制。

信息瓶颈：规定可见范围，或规定必须保留的内容。 前向硬选择把查询的信息来源固定为局部输入。令 I_{in} 表示采样支撑集 $\mathcal{R}_{p,k}^{\text{in}}$ 内的像素，I_{out} 表示其余像素，查询满足条件独立关系

$$\mathcal{I}(Q_{p,k}; I_{\text{out}} \mid I_{\text{in}}, \mathbf{u}_p, k) = 0. \tag{9.4.10}$$

表 9.5: 显式中间表示、Transporter 查询裁剪与 ReconVLA 的机制对照。推理开销列出各方法引入的计算。

维度	显式框、掩码或推理	Transporter 查询裁剪	ReconVLA 局部重建
区域定义	语言条件定位出的对象、目标区或关键点	抓点周围 64×64 窗口；枚举旋转	随操作阶段构造的 gaze 区域
输入通路	中间结果进入策略；可同时保留原图	查询读取局部，键分支读取全图	动作分支保留全局输入
监督通路	感知监督与动作监督，取决于连接方式	示范抓点条件下的放置分类监督	动作监督与局部潜变量去噪共同更新表征
推理开销	在线定位或中间序列生成	旋转查询与密集相关，可批处理	训练后移除辅助分支，直接解码动作
误差传播	错误定位会影响下游，可显式检查	抓点偏差改变查询内容，窗口边界可能截断对象	区域误差先影响训练；全局输入提供上下文
梯度连接	由定位表示与策略连接方式决定	抓取与条件放置分别接受监督	动作与重建共同更新共享表征
时间信息	可通过历史定位结果扩展	标准前馈形式读取当前观察	当前局部监督，可结合时序骨干

这里 $\mathcal{I}(\cdot;\cdot\mid\cdot)$ 为条件互信息。给定局部内容和抓取条件，改变外部像素不会给查询增加信息；这与式 (9.4.5) 的零梯度及图 9.7 的支撑范围相对应。全局场景信息经键特征 F 进入相关评分，形成“局部物体模板与全局放置环境”的分工。

反向软塑形则把信息保留要求写成优化约束。记局部恢复的期望失真为 $\mathcal{D}_R$，可将动作学习写为

$$\min_{\theta,\phi}\mathcal{L}_{\text{act}}\quad\text{s.t.}\quad\mathcal{D}_R(\theta,\phi)\le\kappa,\qquad\mathcal{D}_R=\mathbb{E}\|\varepsilon-D_\phi(z_\tau,\tau,c_t)\|^2. \tag{9.4.11}$$

其拉格朗日形式为 $\mathcal{L}_{\text{act}}+\lambda_{\text{rec}}(\mathcal{D}_R-\kappa)$，其中 $\lambda_{\text{rec}}\ge0$。去掉与参数无关的常数项后，便得到式 (9.4.7) 的联合目标。κ 描述局部恢复的精度要求，λ_{rec} 控制相应梯度的权重。在有限容量的共享表征中，重建目标提高碗口边缘、物体轮廓等信息被保留的价值，而全局输入继续提供容器位置与周围环境。

两种机制由此形成清晰的取舍：硬选择直接规定查询的输入支撑，软塑形通过目标函数调整共享编码的内容。例如，长条物体一端进入固定窗口时，查询只编码该端的局部形状，另一端的场景证据由全图键承载；采用全局共享表征时，模型可以联合编码两端关系，局部恢复目标则强调当前接触端的细节。前者把分工写进计算结构，后者把信息需求写进训练目标。

9.4.6 从固定局部到阶段、预算与具身关系

抓取前的物体表面、搬运中的障碍、放置时的容器边缘，构成随阶段切换的证据集合。有限计算预算要求筛选有效 token，LightVLA 与 DTP 围绕这一问题减少视觉冗余 [16,17]；遮挡与阶段切换要求利用过去的交互状态，AVA-VLA 以历史条件调节注意力 [18]；视觉区域还需要与执行器位置建立联系，GeoProp 则将本体状态引入空间锚定 [19]。计算预算、时间条件与具身参照共同决定当前应保留哪些证据。

将历史阶段判断与末端几何锚定结合，可构造时变选区过程：

$$b_t = F_\omega(b_{t-1}, o_t, a_{t-1}, l), \qquad R_t \sim p_\eta(R \mid b_t, l, q_t), \qquad \mathbf{u}_t^{\mathrm{ee}} = \Pi_{\mathcal{K}}(\mathbf{x}_t^{\mathrm{ee}}). \tag{9.4.12}$$

其中 b_t 汇总交互历史，$\Pi_{\mathcal{K}}$ 通过相机标定将末端位置投影到图像。抓取前，选区围绕目标表面与末端展开；抬升后，历史状态触发阶段切换，选区转向搬运路径与目标容器。几何锚点确定当前位置，历史信息决定下一步需要观察的关系。

本节要点

区域选择控制输入范围，局部重建塑造保留内容，历史与几何确定当前阶段需要的证据。任务相关 grounding 的目标，是让策略在视觉变化中持续保留决定接触、避障与放置的关键信息。

9.5 时间演化与闭环泛化：世界模型在决策中的角色

9.5.1 从当前接触证据到动作后果

插头与插孔已经对齐，下一步推进仍可能因摩擦、倾角或接触变形而卡住。当前图像 grounding 解决“依据哪里决策”，时间建模则追问“执行后会怎样”。前者建立可靠的起点，后者预测状态变化；闭环反馈把预测重新接回真实物理过程。

未来预测进入控制系统后，可以作为训练监督、目标条件或候选评价器。用于辅助学习时，预测误差更新共享表征；用于子目标生成时，未来状态成为低层策略的执行目标；用于规划时，候选动作成为预测条件。表 9.6 按这种信息流分工组织相关研究 [20]。

潜在预测线索。 控制需要从纹理变化中提取状态关系，Meta FAIR 的 JEPA 系列在潜在空间中组织这种学习：I-JEPA 预测图像目标区域的表征，V-JEPA 将预测扩展至视频时空区域，编码动态关系 [21,22]。为了比较动作后果，V-JEPA 2 通过动作条件后训练将潜在预测接入规划 [23]；针对局部精度，V-JEPA 2.1 进一步强调稠密特征学习 [24]。

视频先验进入控制。 视觉预测通过动作或目标条件进入控制。Visual Foresight 先提出候选动作，再预测后果并比较代价；SuSIE 先生成子目标图像，再由低层策略到达目标 [25,26]。视频预训练进一步扩大物体运动与场景变化的覆盖，NVIDIA 的 Cosmos 据

表 9.6: 世界模型的系统角色、条件作用形式与控制目标。

角色	信息通路与代表线索	控制目标
辅助监督	当前表征预测目标区域或未来教师特征；JEPA、FRAPPE	通过预测监督提高表征的局部与时间一致性
子目标生成	观测与语言生成目标图，再由低层执行；SuSIE	目标物理可达，低层能够跟踪
联合世界动作策略	同时生成动作与未来状态；Cosmos Policy、DreamZero	动作与状态预测一致，满足控制周期
动作条件规划	候选动作输入预测器，比较未来代价；Visual Foresight、V-JEPA 2-AC	对动作变化响应正确，候选排序与真实执行一致
训练或评估模拟器	接收连续策略动作，生成观测、奖励或终止信号	维持连续交互中的状态、奖励与终止一致性

此构建世界基础模型 [27]。为了把视频先验用于操作，Cosmos Policy 在后训练中加入动作、未来状态与价值预测，DreamZero 则联合建模视频与动作 [28,29]，将视觉演化知识连接到交互决策。

从当前局部到未来表征。 对于操作表征，当前接触细节与后续状态变化构成互补监督。ReconVLA 用区域重建强调当前几何；FRAPPE 通过未来前缀、多教师表征对齐与策略适配引入未来信息 [15,30]。例如，插入前需要保存孔口边缘，插入后需要判断是否已进入正确接触状态。监督的时间位置由当前扩展到未来，推动表征同时编码“眼前有哪些可操作细节”和“交互将使这些细节如何变化”。

9.5.2 局部重建与未来潜在对齐的统一目标

若表征将插孔左右边缘压成同一个向量，精细插入就失去了必要差异；若它只记住边缘纹理、忽略物体是否已被夹住，又无法预测推进后的状态。控制表征需要同时保留当前几何与后续变化的信息。

令任务表征为 $z_t = E_\theta(o_{\le t}, a_{<t}, l)$，其理想作用是压缩历史而保留控制所需的奖励与转移信息：

$$p(r_t, z_{t+1} \mid o_{\le t}, a_{\le t}, l) \approx p(r_t, z_{t+1} \mid z_t, a_t, l). \tag{9.5.1}$$

这一压缩围绕控制目标进行：桌布纹理可以被合并到相近表示，夹爪接触状态和障碍位置则决定奖励与后续转移，需要在表征中保持可区分。

沿这一思路，可以把两种辅助目标接到同一个动作学习问题：

$$\mathcal{L}_{\text{joint}} = \mathcal{L}_{\text{act}} + \lambda_c \mathcal{L}_{\text{current-local}} + \lambda_f \mathcal{L}_{\text{future-latent}}, \tag{9.5.2}$$

$$\mathcal{L}_{\text{current-local}} = \mathbb{E}_{\tau,\varepsilon} \|\varepsilon - D_\phi(z_\tau, \tau, c_t)\|^2, \tag{9.5.3}$$

$$\mathcal{L}_{\text{future-latent}} = \sum_j w_j \mathbb{E}\, d_j\big(H_j(h_t, l), \operatorname{sg}\left(T_j(o_{t+\Delta})\right)\big). \tag{9.5.4}$$

第一项辅助目标恢复当前局部潜变量；第二项用未来观测的教师特征监督历史表征。T_j 指定教师保留的信息，Δ 指定预测跨度，w_j 分配不同教师的监督权重。插入任务中，当前局部项可以强调孔口与插头的边缘，未来项则要求历史表征能够预测推进后的相对位置与接触状态。

式 (9.5.4) 以历史和语言为条件，学习数据中后续状态的规律。规划进一步将候选动作序列 A_t 加入条件，形成 $H_j(h_t, A_t, l)$，并使用带动作记录的交互序列训练。例如，向左微调与直接推进对应不同的未来边缘位置，动作条件使预测器能够分辨这两种后果。目标教师可采用冻结参数，或结合停止梯度与滑动平均稳定更新；固定的特征参照为预测分支提供持续的学习目标。

教师的选择对应表征应保留的尺度。语义教师强调对象和任务关系，稠密视觉教师强调局部对应，时间教师强调状态变化。训练时通过区域范围、时间跨度和损失权重分配有限表征容量，评测时则以“仅动作、当前局部、未来特征、二者结合”四组对照分析各项监督的贡献。

9.5.3 提出动作与提出未来：两种决策分解

抓杯子绕过障碍时，可以先提出左右两条动作序列、再预测后果；也可以先生成杯子到达托盘的目标图、再求到达动作。令 $Y_t = o_{t+1:t+H}$ 为未来观察，$A_t = a_{t:t+H-1}$ 为动作序列，则联合分布有两种链式分解：

$$p(A_t, Y_t \mid h_t, l) = p_\pi(A_t \mid h_t, l)\, p_W(Y_t \mid h_t, A_t, l), \tag{9.5.5}$$

$$= p_G(Y_t \mid h_t, l)\, p_I(A_t \mid h_t, Y_t, l). \tag{9.5.6}$$

前者把候选动作作为预测条件，后者把目标未来作为执行条件。对于绕障任务，动作优先的分解分别输入左绕与右绕轨迹，预测沿途碰撞与终态；未来优先的分解先生成杯子到达托盘的图像，再由低层策略求解到达路径。两种分解把搜索负担分别放在动作候选空间与目标状态空间。

动作条件模型承担“做了会怎样”的计算，其训练与评测围绕动作变化引起的状态分流展开；子目标模型承担“应该变成怎样”的生成，其目标空间应与低层策略的可达范围相匹配。联合生成则让动作与状态共享条件表征，再通过真实交互反馈更新二者的对应关系。

9.5.4 闭环控制中的误差累积与候选排序

模型预测控制在每次决策时搜索有限时域动作，只执行前一段，再依据新观察重新规划：

$$A_t^\star = \arg\min_{A_t} \mathbb{E}_{\widehat{p}_W}\left[\sum_{k=0}^{H-1} c(\hat{z}_{t+k}, a_{t+k}, l) + c_H(\hat{z}_{t+H}, l)\right]. \tag{9.5.7}$$

真实反馈修正初始状态，并缩短预测误差持续累积的时间。例如，每次预测未来十步而仅执行前两步，下一次规划便从两步后的实测状态重新出发。预测时域决定前瞻范围，执行段长度与计算时延共同决定反馈频率。

考虑同一动作序列下的确定性转移 F 与近似模型 $\widehat{F}$。在所考察区域内，设单步模型误差不超过 ϵ，真实转移对状态满足 Lipschitz 条件：

$$\|\widehat{F}(z,a) - F(z,a)\| \le \epsilon, \qquad \|F(z,a) - F(z',a)\| \le L\|z - z'\|. \tag{9.5.8}$$

令 $e_k = \|\hat{z}_{t+k} - z_{t+k}\|$，插入中间项 $F(\hat{z}_{t+k}, a_{t+k})$ 可得

$$e_{k+1} \le \epsilon + L e_k, \qquad e_H \le L^H e_0 + \epsilon \sum_{j=0}^{H-1} L^j. \tag{9.5.9}$$

式 (9.5.9) 将当前感知与未来预测连接起来：局部定位决定初值误差 e_0，单步动力学拟合决定 ϵ，状态敏感程度决定放大系数 L。在接触模式固定的局部区域，三者共同控制预测偏差。

例 9.5.1: 从定位误差到四步预测偏差

考虑仅跟踪平面位置误差的局部模型，取 $L = 1$、初始定位误差 $e_0 = 1\,\mathrm{mm}$、单步模型误差上界 $\epsilon = 0.5\,\mathrm{mm}$。四步预测的误差上界为

$$e_4 \le 1 + 4 \times 0.5 = 3\,\mathrm{mm}.$$

将当前定位改善至 $0.2\,\mathrm{mm}$，该上界降为 $2.2\,\mathrm{mm}$；保持初始定位不变而把单步模型误差降至 $0.1\,\mathrm{mm}$，上界降为 $1.4\,\mathrm{mm}$。局部感知与动力学学习分别减小误差链条中的初值项和累积项，闭环重新观测则重置下一段预测的起点。

对于规划，更直接的要求是把“平稳插入”排在“接触卡死”之前。设固定候选集上真实代价与预测代价满足 $|\widehat{C}(A) - C(A)| \le \delta$，$\widehat{A}$ 精确最小化预测代价，$A^\star$ 最小化真实代价，则

$$C(\widehat{A}) \le \widehat{C}(\widehat{A}) + \delta \le \widehat{C}(A^\star) + \delta \le C(A^\star) + 2\delta, \tag{9.5.10}$$

$$C(\widehat{A}) - C(A^\star) \le 2\delta. \tag{9.5.11}$$

在同一候选集上，预测代价的精度直接约束所选动作的真实代价。若搜索器满足 $\widehat{C}(\widehat{A}) \le \min_A \widehat{C}(A) + \eta_{\mathrm{opt}}$，同样推导得到 $C(\widehat{A}) - C(A^\star) \le 2\delta + \eta_{\mathrm{opt}}$。预测误差与搜索误差由此进入同一决策质量界。

例 9.5.2: 代价间隔与候选保序

设“平稳插入”与“接触卡死”两个候选的真实代价分别为 1 和 3，各自预测误差上界为 $\delta = 0.4$。预测代价分别落在 $[0.6, 1.4]$ 与 $[2.6, 3.4]$ 内，两个区间分离，低代价动作保持领先。若两个动作的真实代价改为 1 和 1.5，预测值 1.4 与 1.1 就会使排序反转，所选动作的代价增加 0.5，仍满足 $2\delta = 0.8$ 的上界。

因此，当候选真实代价间隔大于 2δ 时，排序得到保持；代价接近时，模型需要更高预测精度。对于精细装配，训练重点正是那些仅差微小位姿、却产生不同接触后果的候选。

9.5.5 跨具身迁移：共享世界知识与适配控制量

同一个物体位移，可以由不同机械臂实现，但关节控制量、夹爪几何与控制频率不相同。令机器人类型为 e，低层动作到任务空间作用的映射为

$$u_t = B_e(q_t, a_t^{(e)}), \qquad z_{t+1} \sim P_\phi(\cdot \mid z_t, u_t, e). \tag{9.5.12}$$

例如，两台机械臂都要使杯子沿桌面前移 5 厘米，共享任务空间目标 u_t 可以保持一致，而关节增量由各自的运动学与控制频率决定。B_e 完成平台特定控制量到任务作用的映射，转移模型中的 e 则保留夹爪几何与接触差异。RT-X 与 DreamZero 等跨平台研究围绕这种共享经验与执行适配展开 [6, 29]；评测分别按新任务、新环境和新机器人分组，并记录目标平台的适配数据量。

本节要点

局部监督改善预测的起点，未来监督编码状态演化，动作条件模型比较候选后果，真实反馈修正累积偏差。前瞻与反馈共同构成闭环泛化：前瞻扩大可比较的行动范围，反馈把决策持续对齐到当前物理状态。

9.6 泛化诊断与评测方法论

9.6.1 由受控变化定位泛化机制

泛化诊断的核心是把环境变化与计算环节建立对应：改变抓点，观察放置预测是否遵循刚体补偿；平移输入，测量空间响应如何随动；替换背景，分析动作对无关区域的依赖。每次控制一个物理因素，便能把性能变化追溯到具体的表示与推理过程。

本节采用配套技术解析记录的积木插入实验 [2, 3]。实验使用训练至 10 000 步的官方检查点，在 CPU 上推理；种子 $1, 3, 5$ 的三次闭环回放均以一次抓放完成任务。随后固定种子 1 的观测，进行抓点条件、输入平移和梯度敏感度分析。[3]

[3]检查点名称为 `block-insertion-transporter-10-0`。运行环境、原始诊断数值与执行记录见配套实验材料。

表 9.7: 从数学推导到任务执行的机制分析。

分析层面	本章实例	关注问题
数学推导	刚体补偿、梯度零和、误差界	几何约束与优化目标如何影响决策
合成算例	四接触岛、通道内积、五候选梯度	输出表示与计算算子如何处理离散候选
模型诊断	三抓点、张量平移、局部敏感度	学到的特征如何响应受控变化
任务基准	多任务、不同示范规模实验	结构与数据怎样改变实际任务表现

9.6.2 抓点位移响应：检验刚体关系是否进入预测

固定种子 1 的图像，仅改变抓取条件。一个抓点来自抓取分支的最大值，另两个从物体可见内部区域选取。目标凹槽保持不变，末端放置点应按物体的刚体变换联动。

利用仿真真值，定义物体从当前姿态到目标姿态的变换

$$T_{\mathrm{move}} = T^{\star}_{WO} T^{-1}_{WO}, \qquad \bar{\mathbf{x}}^{\star}_{\mathrm{place}} = T_{\mathrm{move}} \bar{\mathbf{x}}_{\mathrm{pick}}. \tag{9.6.1}$$

齐次坐标上的该变换将当前接触点搬到目标物体上的对应点。将其量化为理想网格位置 $\mathbf{u}_d^{\mathrm{ideal}}$，便可比较

$$e_{\mathrm{pos}} = s_g \|\widehat{\mathbf{u}}_d - \mathbf{u}_d^{\mathrm{ideal}}\|_2. \tag{9.6.2}$$

式中真值位姿用于构造评价参照，策略输入为观测图像与抓点条件。e_{pos} 衡量平面位置偏差，方向索引和实际执行结果分别描述旋转选择与接触效果。

表 9.8: 同一场景三种抓取条件下的预测 [3]。第一行为闭环回放中的动作，后两行为固定图像上的条件推理。

抓点 (r_p, c_p)	预测放置像素	理想放置像素	误差（mm）	方向索引 k
$(118, 49)$	$(41, 21)$	$(42, 20)$	4.42	15
$(136, 72)$	$(13, 11)$	$(15, 9)$	8.84	14
$(140, 50)$	$(21, 30)$	$(22, 30)$	3.13	15

图 9.9 中，三组放置峰随抓点改变，并落在各自几何参照附近，对应平面误差约为 3.1–8.8 mm。网络的条件响应由此表现为：同一物体和凹槽下，改变接触位置会改变末端释放位置。第二组方向索引相差一格，对应 10° 的搜索角间隔，体现了位置补偿与旋转选择两种响应。

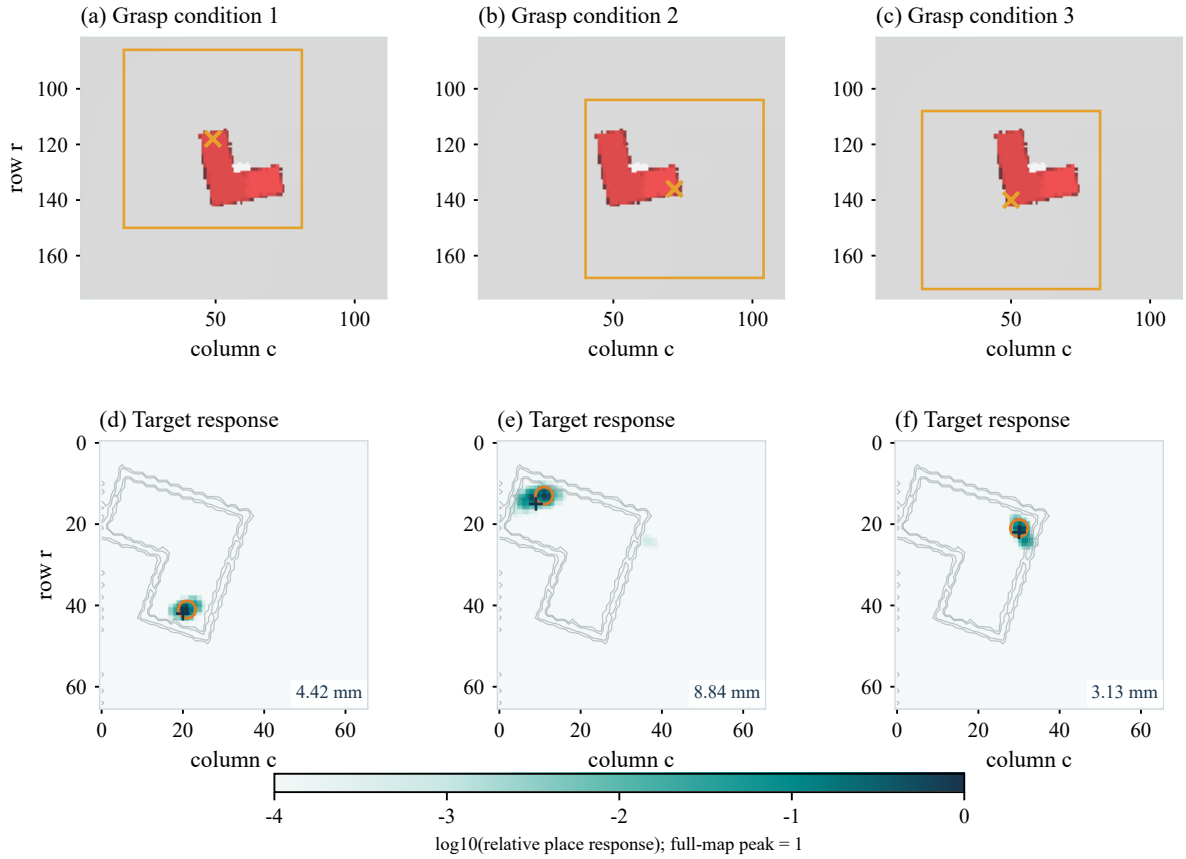


图 9.9: 三种抓取条件下的放置响应 [3]。上排显示抓取窗口，下排显示共享目标视窗；圆圈为预测位置，加号为刚体参照。热图对方向取最大值，再按各自完整图峰值归一化；误差在原始网格中计算。

9.6.3 一个像素与八个像素：采样相位的可测偏差

卷积特征中的下采样把连续的像素平移分成不同采样相位。以一维信号说明，定义 $(\mathsf{D}_s f)[n] = f[sn]$，则对整数 m 有

$$(\mathsf{D}_s \mathsf{T}_{sm} f)[n] = f[s(n-m)] = (\mathsf{T}_m \mathsf{D}_s f)[n]. \tag{9.6.3}$$

输入移动 s 的整数倍时，采样结果随之移动整数格；输入移动一格时，采样点由 sn 变为 $sn-1$，转而读取另一组余数位置。取 $s=8$，原先读取 $0, 8, 16, \ldots$，一格平移后对应 $-1, 7, 15, \ldots$，两组网格的局部细节因而发生变化。

据此，诊断对同一融合图施加一格与八格平移，空出区域补零，抓取条件同步移动。整个变换在输入张量上进行，以隔离网络对采样位置的响应。

令 P' 为新输入的抓取分布，$\widetilde{P} = \mathsf{T}_\delta P$ 为原分布同步平移后的结果。在去掉四边各 32 像素的区域 Ω 内，分别重新归一化：

$$\mathrm{TV}_\Omega(P', \widetilde{P}) = \frac{1}{2} \sum_{\mathbf{u} \in \Omega} \left| \frac{P'(\mathbf{u})}{\sum_\Omega P'} - \frac{\widetilde{P}(\mathbf{u})}{\sum_\Omega \widetilde{P}} \right|. \tag{9.6.4}$$

该量累积内部区域中所有位置的概率差异。即使最高峰保持在同一对应位置，次峰与背景概率的重新分配也会体现在 TV 中。

表 9.9: 固定检查点的张量平移诊断 [3]。放置峰误差以原峰同步平移后的位置为参照；TV 保留三位小数，低于 10^{-7} 的值按阈值报告。

平移位移 $(\Delta r, \Delta c)$ (px)	抓取分布总变差 TV_Ω	放置峰平移误差	预测方向索引 k
$(0, 0)$	0.000	0 px	15
$(1, 0)$	0.065	0 px	15
$(0, 1)$	0.104	0 px	15
$(8, 0)$	$< 10^{-7}$	0 px	15
$(0, 8)$	$< 10^{-7}$	0 px	15
$(8, 8)$	$< 10^{-7}$	0 px	15

表 9.9 中，1 像素平移引起约 6.5%–10.4% 的总变差，而 8 像素平移后的总变差低于 10^{-7}。这与式 (9.6.3) 的相位关系一致：前者改变下采样读取的像素组，后者保持网格对应。六种条件下放置最高峰均随输入同步平移，抓取分布的 TV 则揭示了峰位之外的概率重排。分布指标与峰值指标分别描述空间响应的整体形状和最终动作选择。

正交网格之外，还应单独检查标定误差。若外参存在小平移 δt 和小旋转 $\delta\phi$，点位置的一阶误差近似为

$$\delta \mathbf{x} \approx \delta t + \delta\phi \times (\mathbf{x} - \mathbf{o}). \tag{9.6.5}$$

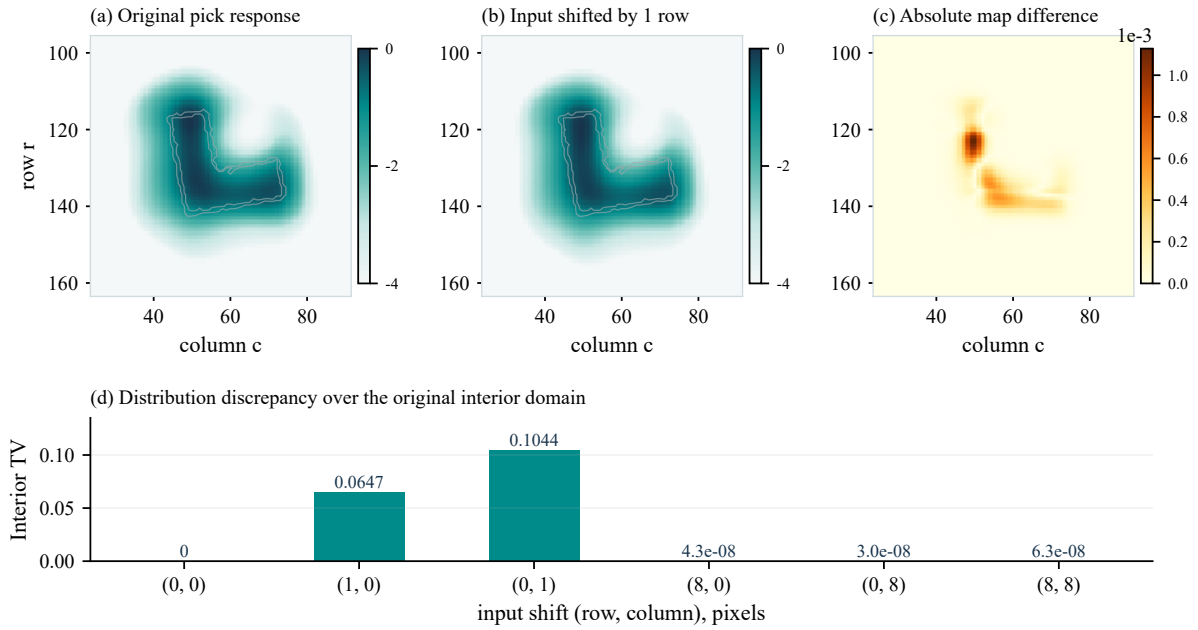


图 9.10: 1 像素与 8 像素平移的比较 [3]。(a,b) 原图与下移一行后的抓取响应；(c) 新分布与同步平移参照的绝对差；(d) 按式 (9.6.4) 计算的内部区域 TV，图中标出原始计算值。

相同角度偏差在较远位置造成更大位移。例如，绕竖直轴的标定角误差为 0.1°，距离该轴 $0.5\,\mathrm{m}$ 的水平点产生约 $0.87\,\mathrm{mm}$ 的横向误差。因此，像素定位、坐标标定与末端控制共同组成装配精度预算。

9.6.4 最差组性能与区域反事实干预

对未见对象、背景、相机与机器人分别分组，报告平均成功率之外的最差组成功率：

$$\widehat{\mathrm{WGS}} = \min_{g \in \mathcal{G}} \frac{1}{n_g} \sum_{i=1}^{n_g} \mathbb{I}[\mathrm{success}_{g,i}]. \tag{9.6.6}$$

组划分在测试前固定，各组同时报告样本数与置信区间。例如，已见背景、未见背景和未见视点三组成功率分别为 90%、70% 和 50% 时，最差组成功率为 50%，直接定位到视点变化这一薄弱环节。

区域干预则直接检查策略依赖。设 J 为一组可重置初始条件下的期望任务回报，用替换算子 $\mathcal{C}_R$ 改变策略看到的区域，定义

$$\Delta_R = J(\pi_\theta; \mathcal{E}) - \mathbb{E}_\nu J(\pi_\theta \circ \mathcal{C}_R(\cdot; \nu); \mathcal{E}). \tag{9.6.7}$$

该实验保留环境动力学，改变观测通路，并为不同区域匹配替换面积、纹理自然性与初始状态。分别干预目标、夹爪、放置区和背景，可以比较策略对不同证据的依赖。例如，以成功率为回报，原策略为 0.8，替换背景后为 0.78、替换接触区后为 0.5，则两区域的

回报下降分别为 0.02 与 0.30。结合动作分布变化，可观察局部重建是否将依赖从背景转向接触证据。

表 9.10: 由机制出发构造评测矩阵。

待检验机制	受控变化	指标与对照
空间共享	整图同步平移、单对象移动分别测试	TV、峰位移误差；边界与内部区域分开
抓放条件依赖	同场景改变抓点	刚体参照误差、方向误差、实际接触成功率
局部证据保留	等面积目标或背景替换	Δ_R；动作基线、显式定位、局部重建
未来信息贡献	固定初态改变候选动作	预测响应、候选排序、真实闭环收益
时间与具身泛化	遮挡、阶段切换、机器人或延迟变化	完整成功率、恢复次数、分组保留率
计算预算	固定端到端延迟或显存上限	成功率–延迟曲线；计入定位、解码与规划

在 CALVIN ABC→D 的 grounding 对照中，采用 gaze 区域重建及视觉预训练的 ReconVLA 将五个连续子任务全部成功的比例从动作监督基线的 49.0% 提升到 64.1%，平均完成长度从 3.36 提升到 3.95 [15]。前一个指标衡量完整任务链的可靠性，后一个指标统计失败前能够连续完成的子任务数量，二者共同描述长时程执行表现。针对具体机制的消融则固定任务、数据、预训练与计算预算，以同一评价指标比较所考察的训练目标。

对当前局部与未来潜在监督的组合，建议固定基础模型、示范集合和训练步数，比较四组目标：$\mathcal{L}_{\text{act}}$、$\mathcal{L}_{\text{act}} + \lambda_c \mathcal{L}_c$、$\mathcal{L}_{\text{act}} + \lambda_f \mathcal{L}_f$、三项联合。新增参数和额外教师数据另列。若还预测物理成功概率 $\hat{p}_i$，可用 Brier 分数

$$\text{BS} = \frac{1}{n} \sum_i (\hat{p}_i - y_i)^2, \qquad y_i \in \{0, 1\} \tag{9.6.8}$$

检验成功概率的校准质量，并按预测概率分组比较实际成功率。这里 $\hat{p}_i$ 由以任务成败标签训练的成功预测器给出；例如，某次成功任务被预测为 0.8，其平方误差贡献为 $(0.8 - 1)^2 = 0.04$。

9.6.5 最小复跑闭环与代码定位

理解公式之后，应沿“坐标转换、抓取评分、条件相关、物理执行”追踪一次决策。固定 Ravens 源码的四个入口如下 [2]：

1. `ravens/agents/transporter.py`：融合 RGB-D，转换监督坐标，连接双位姿动作。
2. `ravens/models/attention.py`：抓取评分、全图归一化与分类损失。

3. `ravens/models/transport.py`：旋转裁剪、查询与键编码、密集相关。
4. `ravens/utils/utils.py`：高度图、像素–世界坐标与几何增广。

在配套代码仓库根目录下，依次评估预训练权重、检查单步训练更新并生成模型诊断：

```
bash scripts/eval_pretrained.sh
bash scripts/smoke_train.sh
source env.sh
python teaching/scripts/model_diagnostics.py --out teaching
```

第一项评估官方权重，第二项将单步训练结果写入独立检查目录，后两行加载实验环境并生成模型诊断。

完整环境配置与运行记录见配套实验材料。复跑按四步展开：核对输入尺度与坐标，检查概率归一化和张量形状，确认模型保存加载，执行闭环回放。前两步定位几何与数值实现问题，后两步检查模型状态与实际动作效果。

本节要点

诊断应与机制一一对应：几何关系看受控位移，信息依赖看区域干预，动力学能力看动作后果，泛化收益看隔离测试。所有结果都应附带实验单位、试验数量和部署预算。

9.7 本章小结与进阶推演

9.7.1 四层泛化框架

具身操作中的泛化，要求变化中的观测与动作始终服从可复用的物理关系。Transporter 把抓放依赖和空间共享写入网络，空间语义路线将其扩展到语言与三维表示，通用 VLA 以预训练扩大数据覆盖，ReconVLA 通过重建保存局部证据，世界模型则加入时间演化约束。它们分别作用于四个层面：

1. **数据覆盖**。对象、场景、指令和机器人经验决定可学习的变化范围，数据混合与测试隔离组织这些经验的复用和检验。
2. **表征塑形**。区域输入、局部重建与未来教师规定哪些信息应保留。夹爪接触区和路径障碍的意义随任务阶段变化。
3. **动作表征**。条件抓放、离散 token 和连续生成决定可表达的动作分布。多峰表示与坐标适配共同组织可执行候选。
4. **动力学一致性**。动作应引起合理的状态变化，预测应帮助选择真实有效的动作，反馈应及时修正偏差。

四层机制通过闭环交互相互连接：局部感知确定未来预测的初值，控制量映射把任务目标落实到机器人，数据分布决定结构先验所拟合的交互经验。分析一个失败案例时，可

以依次追问观测是否覆盖关键证据、动作是否保留可行模式、预测是否保持物理关系、反馈是否及时修正偏差，再选择相应的学习目标和结构约束。

9.7.2 四个动手推演

以下练习以具体数值与位姿关系，分别检查概率分解、坐标约定、统计口径与任务对称性 [3]。

1. **贪心抓放为何不等于联合最优？**两个抓点的概率为 $p(p_1) = 0.6, p(p_2) = 0.4$。给定 p_1，两个放置候选的概率为 $(0.51, 0.49)$；给定 p_2，概率为 $(0.95, 0.05)$。分别计算贪心结果与联合 MAP。若只评估前 B 个抓点，写出搜索规则，并说明什么时候能恢复全局最优。
   提示：比较 $p(p_i)\max_j p(b_j \mid p_i)$，而非只比较 $p(p_i)$。

2. **像素坐标是否写反？**取 $s_g = 0.003125\,\mathrm{m}$、$X_{\min} = 0.25\,\mathrm{m}$、$Y_{\min} = -0.5\,\mathrm{m}$，将 $(r, c) = (80, 40)$ 转为世界水平坐标。再向世界 X 正方向移动 $0.03125\,\mathrm{m}$，求新网格位置。若改用网格中心约定，结果应增加什么偏移?
   提示：先写 $r \leftrightarrow Y$、$c \leftrightarrow X$，再代入式 (9.2.9)。

3. **相同平均得分能否对应不同完整成功率？**一个任务含四个等权子目标，两组各测试十次。第一组每次完成两个子目标；第二组五次全部完成、五次一个也没完成。计算两组平均任务得分与完整成功率。进一步说明为什么表 9.3 的部分奖励任务需要同时报告两类指标。
   提示：每回合得分取已完成子目标数除以四，完整成功要求四个全部完成。

4. **两个放置峰是对称正确解，还是混淆伪峰？**固定抓取关系 T_{GO}，把两个候选末端位姿 $T_{WG}^{(1)}, T_{WG}^{(2)}$ 分别映射为物体位姿 $T_{WO}^{(i)} = T_{WG}^{(i)} T_{GO}$。若任务允许物体的对称群为 $\mathcal{H}$，写出候选与目标等价的判据；再说明如何通过动作执行检查接触可行性。
   提示：比较 $\min_{S \in \mathcal{H}} d(T_{WO}^{(i)}, T_{WO}^{\star} S)$ 与任务容差，以对称关系判断位姿等价，再以实际执行判断接触可行性。

本节要点

贯穿全章的判断尺度是：**变化发生后，任务所需的几何、信息与动力学关系是否仍然成立？**将这一问题转化为可推导的关系、可干预的变量和可复查的实验，就能把泛化落实为具体的结构设计、训练目标与闭环控制方法。

参考文献

[1] Zeng, A., Florence, P., Tompson, J., et al. Transporter Networks: Rearranging the Visual World for Robotic Manipulation. In *Conference on Robot Learning*, 2020. https://arxiv.org/abs/2010.14406.

[2] The Ravens Authors. Ravens: A Collection of Simulated Tasks in PyBullet for Learning Vision-Based Robotic Manipulation. Official code and checkpoints. https://github.com/google-research/ravens. 本章使用固定源码快照；完整提交与环境记录见配套材料。

[3] *Transporter Networks*：从空间对应到操作策略（修改副本）. 随章配套技术解析与复现材料，未出版稿，2026 年 9 月。源目录 `Transporter_Networks_Source_Revision/transporter_book_revision`；PDF：`Transporter_Networks_Technical_Guide_Revision.pdf`。本章合成算例、教学重绘与模型诊断的直接来源。

[4] Zitkovich, B., et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. In *Conference on Robot Learning*, 2023. https://proceedings.mlr.press/v229/zitkovich23a.html.

[5] Kim, M. J., et al. OpenVLA: An Open-Source Vision-Language-Action Model. In *Conference on Robot Learning*, 2024.

[6] Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models. In *IEEE International Conference on Robotics and Automation*, 2024.

[7] Brohan, A., et al. RT-1: Robotics Transformer for Real-World Control at Scale. *arXiv:2212.06817*, 2022. https://robotics-transformer1.github.io/.

[8] Shridhar, M., Manuelli, L., Fox, D. CLIPort: What and Where Pathways for Robotic Manipulation. In *Conference on Robot Learning*, 2021; PMLR 164, 2022. https://proceedings.mlr.press/v164/shridhar22a.html.

[9] Shridhar, M., Manuelli, L., Fox, D. Perceiver-Actor: A Multi-Task Transformer for Robotic Manipulation. In *Conference on Robot Learning*, 2022; PMLR 205, 2023. https://proceedings.mlr.press/v205/shridhar23a.html.

[10] Goyal, A., et al. RVT: Robotic View Transformer for 3D Object Manipulation. In *Conference on Robot Learning*, 2023. https://proceedings.mlr.press/v229/goyal23a.html.

[11] Goyal, A., et al. RVT-2: Learning Precise Manipulation from Few Demonstrations. In *Robotics: Science and Systems*, 2024. https://www.roboticsproceedings.org/rss20/p055.pdf.

[12] Chi, C., Feng, S., Du, Y., et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. In *Robotics: Science and Systems*, 2023. https://arxiv.org/abs/2303.04137. 项目页：https://diffusion-policy.cs.columbia.edu/.

[13] Huang, H., et al. RoboGround: Robotic Manipulation with Grounded Vision-Language Priors. In *CVPR*, 2025.

[14] Zawalski, M., et al. Robotic Control via Embodied Chain-of-Thought Reasoning. *arXiv:2407.08693*, 2024.

[15] Song, W., et al. ReconVLA: Reconstructive Vision-Language-Action Model as Effective Robot Perceiver. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(22):18549–18557, 2026; preprint 2025. https://doi.org/10.1609/aaai.v40i22.38921. 预印本：https://arxiv.org/abs/2508.10333.

[16] Jiang, T., et al. The Better You Learn, The Smarter You Prune: Towards Efficient Vision-Language-Action Models via Differentiable Token Pruning. *arXiv:2509.12594*, 2025.

[17] Li, C., et al. DTP: A Simple yet Effective Distracting Token Pruning Framework for Vision-Language Action Models. *arXiv:2601.16065*, 2026.

[18] Xiao, L., et al. AVA-VLA: Improving Vision-Language-Action Models with Active Visual Attention. In *CVPR*, 2026.

[19] Zhao, G., et al. GeoProp: Grounding Robot State in Vision for Generalist Manipulation. *arXiv:2607.07101*, 2026.

[20] Hou, B., Li, G., Jia, J., et al. World Model for Robot Learning: A Comprehensive Survey. *arXiv:2605.00080*, 2026. 本章引用 v1。https://arxiv.org/abs/2605.00080v1.

[21] Assran, M., et al. Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023. https://arxiv.org/abs/2301.08243.

[22] Bardes, A., et al. Revisiting Feature Prediction for Learning Visual Representations from Video. *arXiv:2404.08471*, 2024. https://arxiv.org/abs/2404.08471.

[23] Assran, M., et al. V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning. *arXiv:2506.09985*, 2025. https://arxiv.org/abs/2506.09985.

[24] Mur-Labadia, L., et al. V-JEPA 2.1: Unlocking Dense Features in Video Self-Supervised Learning. *arXiv:2603.14482*, 2026. https://arxiv.org/abs/2603.14482.

[25] Finn, C., Levine, S. Deep Visual Foresight for Planning Robot Motion. In *IEEE International Conference on Robotics and Automation*, 2017; preprint 2016. https://arxiv.org/abs/1610.00696.

[26] Black, K., Nakamoto, M., Atreya, P., et al. Zero-Shot Robotic Manipulation with Pretrained Image-Editing Diffusion Models. In *International Conference on Learning Representations*, 2024; preprint 2023. https://arxiv.org/abs/2310.10639.

[27] NVIDIA, et al. Cosmos World Foundation Model Platform for Physical AI. *arXiv:2501.03575*, 2025. https://arxiv.org/abs/2501.03575.

[28] Kim, M. J., et al. Cosmos Policy: Fine-Tuning Video Models for Visuomotor Control and Planning. In *International Conference on Learning Representations*, 2026. https://arxiv.org/abs/2601.16163.

[29] Ye, S., et al. World Action Models are Zero-shot Policies. *arXiv:2602.15922*, 2026. https://arxiv.org/abs/2602.15922.

[30] Zhao, H., et al. FRAPPE: Infusing World Modeling into Generalist Policies via Multiple Future Representation Alignment. *arXiv:2602.17259*, 2026. https://arxiv.org/abs/2602.17259.